

**Le traitement automatique de la langue  
contre les erreurs judiciaires :  
une méthodologie d'analyse systématique des textes  
d'un dossier d'instruction**

Yannick Toussaint

LORIA – INRIA  
BP 239  
54506 Vandoeuvre-lès-Nancy  
Yannick.Toussaint@loria.fr

**Résumé – Abstract**

Cet article présente une méthode d'analyse systématique et scientifique des documents constituant un dossier d'instruction. L'objectif de cette approche est de pouvoir donner au juge d'instruction de nouveaux moyens pour évaluer la cohérence, les incohérences, la stabilité ou les variations dans les témoignages. Cela doit lui permettre de définir des pistes pour mener de nouvelles investigations. Nous décrivons les travaux que nous avons réalisés sur un dossier réel puis nous proposons une méthode d'analyse des résultats.

This article presents a systematic and scientific method to analyse the set of documents that constitutes a file of instruction. The goal of this approach is to give the examining magistrate new means to estimate the coherence, the incoherence, the stability or the variations in the testimonies. This analysis should help him in identifying the needs for new investigations. We applied our method to a real file and then we propose a way to read the results.

**Keywords – Mots Clés**

Catégorisation, synthèse, questionnabilité d'un texte, traitement cognitifs d'un texte, traitement automatique de la langue, Justice, dossier d'instruction.

Text categorisation, text synthesis, text questioning, cognitive treatment of texts, Justice and natural language processing.

# 1 Objectifs

« L'attente des Français n'a jamais été aussi forte en terme de sécurité et de justice. Nos concitoyens veulent des réponses simples, rapides et efficaces. Il veulent renouer avec leur justice et se retrouver dans ses actes et décisions (...) Il appartient à l'institution judiciaire d'assurer la sécurité des rapports juridiques entre les citoyens, l'efficacité des décisions rendues et la protection de la société contre le crime et la délinquance. Or, la justice ne dispose pas à l'heure actuelle des moyens nécessaires à un traitement satisfaisant des affaires dont elle est saisie : des délais trop longs et des procédures complexes nourrissent le sentiment d'incompréhension et la perte de confiance à son égard. » (La loi d'orientation et de programmation pour la Justice 2003-2007, *Justice : les moyens d'agir*, 9 sept 2002, Ministère de la Justice, p.1)

Disposer d'une justice qui se donne les moyens de mener jusqu'au bout ses enquêtes et ses recherches est enjeu sociétal très important. Il est, en effet, vital pour une démocratie que la justice puisse échapper aux phénomènes de mode, à la pression médiatique, qu'elle prenne des décisions raisonnées, et que la charge de travail importante des magistrats ne soit pas une excuse pour négliger certaines instructions dans lesquelles seule une étude très minutieuse des faits et des documents peut révéler la vérité. Les anomalies, incohérences ou mensonges dans un dossier (toujours relevées par le détective dans le roman policier !) sont souvent noyées dans un volume considérable de papiers et, s'il n'y a pas une armée d'avocats pour tout passer à la loupe et les repérer, le dossier n'est tout simplement pas étudié en détail. Juges et avocats croulent sous les dossiers, nombre de détails importants leur échappent et l'erreur judiciaire pèse comme une menace sur chaque dossier.

Cet article vise à montrer, par une expérimentation réelle, que les techniques et méthodes du traitement automatique de la langue (TAL) peuvent être appliquées avec succès à de nouveaux domaines comme les procédures judiciaires. Nous nous proposons ici, de poser les bases d'une méthode scientifique d'analyse des dossiers d'instruction. Cette méthode est tout particulièrement appropriée lorsque les témoignages jouent un rôle prépondérant, notamment, en l'absence de preuves matérielles. C'est, par exemple, le cas dans les affaires de mœurs. L'augmentation très importante du nombre de plaintes dans ce domaine cache aussi une recrudescence des fausses accusations : l'Autonome de Solidarité (Association assurant la défense des enseignants) estime que sur 208 affaires de mœurs enregistrées chez elle et closes aujourd'hui, seules 26 ont fait effectivement l'objet de condamnations.

La méthode exposée dans cet article met en valeur les propos de chaque individu, souligne l'évolution ou la stabilité de ces propos dans le temps et finalement, met au jour la cohérence ou les incohérences de leurs discours. Elle permet également de faciliter l'identification de certaines zones d'ombre qu'il peut être important pour le dossier de lever. Bien évidemment, nos travaux n'ont pas la prétention de prendre une décision à la place du juge et cette méthode se place donc en complément d'autres sources d'investigation déjà connues.

Ainsi, des tests psychologiques de personnalité (Davido, 1997 et HandTest, 1983) sont pratiqués à la demande de la justice par certains psychologues et dans certaines régions. Mais la compréhension de l'affaire est fréquemment beaucoup plus complexe et dépasse le niveau de l'individu. (Bensussan, 1999 et 2002) montrent notamment que les situations de crise dans une famille peuvent constituer un contexte favorable à la formulation d'allégations mensongères. Faire la part entre mensonges et vérité nécessite alors beaucoup de détermination. Lorsqu'il s'agit d'un enfant par exemple, mettre en doute sa parole s'il a effectivement subi une agression a des conséquences dramatiques sur son équilibre psychologique et compromet également l'issue normale du procès. Cependant, croire, sans chercher à les remettre en cause, aux allégations mensongères d'un enfant, conduit progressivement à l'enfermer dans son mensonge et induit des conséquences que (Bensussan, 1999) qualifie de plus graves encore que s'il avait été victime. Il convient donc d'être très prudent et très fin dans l'analyse d'un dossier et d'observer un détachement suffisant pour ne pas se laisser leurrer par des apparences.

Nous ne nous intéressons ici qu'à la démarche scientifique et non à l'affaire elle-même. Nous définissons en premier lieu les besoins et les contraintes à prendre en compte. Nous décrivons ensuite notre expérimentation. Enfin, nous analysons les résultats de notre démarche et évaluons l'apport de

nos travaux par la présentation de résultats qualitatifs. Cet article ne citera à titre d'exemple que quelques éléments d'information pour illustrer nos propos et le lecteur n'aura donc qu'une vue très partielle qui ne lui permettra pas de comprendre ou de juger la globalité du dossier. Pour aider à la compréhension de nos exemples, nous désignons les deux personnes (d'une même fratrie) ayant déposé plainte par Acc1 et Acc2 et la personne mise en examen par MeE. Les autres intervenants sont désignés par le lien les reliant à une de ces trois personnes (ex : cousin(Acc1)).

## 2 Méthodologie d'analyse

Même si les avocats peuvent également être intéressés par notre méthode, l'utilisateur premier d'une telle analyse est le juge d'instruction, c'est-à-dire, la personne qui doit assumer la difficile tâche d'instruire le dossier à **charge et à décharge**. Nous avons contraint notre méthode pour qu'en premier lieu, elle permette de réduire la masse d'information du dossier à l'information utile puis qu'elle la rende facilement accessible en la déformant le moins possible. L'information sera donc catégorisée (au sens de la catégorisation de textes en TAL). L'analyse doit également être objective, fiable, explicable, interprétable, traçable. Enfin, le processus doit être incrémental, c'est-à-dire, permettre de saisir progressivement les documents composant le dossier d'instruction et de prendre en compte de nouveaux documents.

Pour se conformer au cahier des charges, nous avons défini une méthodologie en 4 points : (1) définir les différentes catégories selon lesquelles l'utilisateur veut analyser l'information contenue dans les textes ; (2) rechercher dans les textes, tous les éléments d'information relevant d'au moins une des catégories et leur associer la liste des catégories pertinentes ; (3) Regrouper ces informations par catégories ; (4) mettre en forme un document synthétique. Dans cette première expérimentation, les étapes 1 et 2 ont été réalisées manuellement.

## 3 Réalisation

### 3.1 Définition des catégories

Le choix des catégories dépend, bien sûr, de la nature du dossier. Les catégories peuvent être vues comme un type de questions auxquelles l'utilisateur souhaite avoir une réponse. Ainsi, « Repères spaciaux de Acc1 » serait associé à la question générique « Où se passent les faits décrits par Acc1 ? », « Personnalité de Acc1 » serait associé à la question « quels sont les traits de caractères de Acc1 ». De plus, les catégories sont recouvrantes : des fragments de texte associés à la catégorie « repères temporels de X » seront souvent présents également dans « repère spaciaux de X ».

<i><b>Personnalités et relations entre défense et accusation :</b></i>	<i><b>Eléments de la défense</b></i>
Personnalité et caractère de MeE(A2)	Impossibilités matérielles relevées (H3)
Vie familiale de MeE (A3)	Réfutation des accusations par les personnes interrogées(H4)
Equilibre familiale chez MeE (A5)	Recherche des motivations des accusations (I1)
Habitudes de famille chez MeE(A7)	<i><b>Eléments de l'accusation :</b></i>
Vie sentimentale et sexuelle de MeE (A6)	Repères spaciaux de Acc1 (H71), de Acc2 (H72)
Relations de MeE avec ses petits-enfants (A11)	Repères temporels de Acc1 (H81), de Acc2 (H82)
Personnalité de Acc1 (B1), de Acc2 (C1)	Descriptions des faits de Acc1 (H10), de Acc2 (H9)
Eléments médicaux de Acc1 (B2), de Acc2 (C2)	<i><b>Analyse globale du dossier</b></i>
Person. de Mère(Acc1 et 2) (D1), de Père(Acc1-2) (E1)	interventions du juge d'instructions dans le dossier(H51)
Rel. entre Mère(Acc1 et 2) et la famille de MeE (F1)	

Figure 1 : quelques catégories parmi celles retenues pour classer les portions de textes

### 3.2 Le fragment de texte

Le dossier d'instruction est un ensemble de documents, certains purement administratifs ou judiciaires rapportent des décisions de la cours mais présentent peut d'intérêt pour notre étude. La plupart des documents, sont des lettres, des auditions de témoins, des transcriptions d'interrogatoire ou de confrontation, des compte-rendus d'expertise. Ces documents papier représentent dans notre affaire environ 1000 pages dactylographiées ou manuscrites. Le fragment de texte est la notion clé qui va nous permettre de garder au moins toutes les portions de textes contenant une information utile. Pour cela nous avons privilégié le bruit au silence, c'est à dire que nous avons préféré sélectionner

trop de fragments plutôt que d'en oublier. Les fragments de texte sont les éléments destinés à être classés dans les catégories. Ils doivent être autonomes, c'est-à-dire que, extraits de leur texte initial et placés dans des catégories, les informations que portent les fragments sont toujours intelligibles. Un fragment de texte doit donc vérifier les propriétés suivantes : (1) Un fragment de texte peut être constitué d'une partie de phrase, d'une phrase ou de plusieurs phrases ; (2) Une portion de texte ne peut être considéré comme fragment que parce qu'elle participe à au moins une des catégories prédéfinies ; (3) Le fragment respecte le découpage syntagmatique du texte, et c'est une unité autonome du point de vue sémantique et pragmatique : isolé de son contexte, le fragment est interprété par l'utilisateur de la même façon que s'il était resté dans son contexte. Les anaphores ou les élipsses situées dans un fragment doivent donc faire l'objet d'une annotation manuelle permettant leur résolution par le lecteur.

La Figure 2 donne des exemples de fragments extraits de divers documents. Les éléments de contexte indispensables à la compréhension du fragment sont introduits dans le texte entre parenthèses comme dans la résolution d'anaphores (par exemple : « Ce dernier (MeE) »). Lors de la retranscription d'un dialogue, nous précisons les intervenants et lorsqu'il s'agit d'une réponse, nous précisons l'énoncé de la question comme par exemple : « ((Av. défense) Votre femme conduisait elle ?) (MeE) Non. »

C30a (Au_Témoin, Nièce(MeE), jj/mm/aa) :	Ce dernier (MeE) se comportait comme un grand-père gâteau. Leur vie à tous les deux (MeE et son épouse) était tournée vers les petits enfants dès qu'ils étaient présents.
A60b (Exp_Psycho (Dr Alpha, MeE), , jj/mm/aa) :	Les mobiles intellectuels qui inspirent habituellement sa (MeE) conduite sont la volonté de bien se faire comprendre d'autrui, au travers d'argumentations précises et fournies. A aucun moment, n'est apparu de volonté de manipulation d'autrui.
D43k (Interr.(juge, MeE), jj/mm/aa) :	((Av. défense) Votre femme conduisait elle ?) (MeE) Non.

Figure 2 : Exemples de fragments de texte issus du dossier d'instruction

En plus de la portion de texte extraite des documents, des métadonnées sont incluses dans le fragment de texte. A60b, appelé clé, identifie le fragment de façon unique : A60 (voir Figure 2) fait référence à la page dans le dossier, et b (que nous appelons l'identifiant) assure l'unicité de la clé. Les identifiants sont attribués de façon séquentielle aux différents fragments issus d'une même page de telle façon que A60a est situé dans la page A60 avant A60b qui lui-même est avant A60c. On peut ainsi, sur la base d'un tri, construire une sorte de résumé de chaque document qui ne contiendrait que les informations utiles. On trouve le type de document (Au\_Témoin : audition de témoin, Interr(juge) : interrogatoire par le juge, Exp\_Psycho (Dr Alpha) : expertise du Docteur Alpha). Enfin, la date (notée ici jj/mm/aa) peut être utilisée pour situer les propos dans le temps et en observer éventuellement l'évolution.

A l'heure actuelle, s'agissant d'une première expérimentation, l'extraction des fragments a été faite manuellement.

### 3.3 Mise en forme automatique de la synthèse du dossier

Chaque fragment est alors associé à une ou plusieurs catégories, également de façon manuelle, comme, par exemple, les catégories A2 et A11 pour le fragment B5a:

A2,A11,	D5a (Au_Témoin, belle-fille(MeE), jj/mm/aa) : MeE est quelqu'un de gentil, attentionné, disponible, il s'occupe de <i>ma fille XX</i> de la même manière qu'il s'occupe de YY, la fille que j'ai eue avec <i>son fils</i> .
---------	---

La mise en forme du document de synthèse est ensuite automatique et rassemble les fragments par catégorie. La mise à jour de ce document est donc très rapide. Ses sections et sous-sections sont constituées par les catégories qui ont été définies. Quelques sections d'information (aide à la lecture du document, liste des documents pris en compte) y sont également systématiquement ajoutées.

## 4 Analyse des résultats

Dans cette section, nous montrons ce que nos travaux apportent à la compréhension du dossier d'instruction. Nous décrivons, en même temps, la méthodologie d'analyse qualitative du document de synthèse. Dans cet article nous aborderons quatre points : (1) l'étude des caractères des personnes en présence dans le dossier (défense et accusation), (2) l'identification de contradictions dans les propos

ou, au contraire, l'observation de la stabilité de certains autres, (3) l'analyse de certains manques dans le dossier, et, enfin, (4) l'analyse du déroulement de la procédure d'instruction.

En premier lieu, donnons une rapide vision quantitative du dossier : nous avons dû numériser tous les fragments retenus. Nous avons isolé dans tout le dossier d'instruction, 950 fragments, 25 000 mots, soit une moyenne de 26 mots par fragments. La taille des fragments est très variable : de trois mots à un paragraphe entier. La répartition de ces fragments dans des catégories a donné 2032 couples. Le document word de synthèse fait 58 pages (times, 12 pts), ce qui est tout à fait analysable manuellement. L'analyse des résultats est faite à partir du document de synthèse qui est produit pour l'utilisateur.

#### 4.1 Analyse des caractères des personnes en présence

La lecture des différentes catégories rassemblant les traits de chacune des personnalités présente un intérêt dans la mesure où elles permettent à l'utilisateur de notre méthodologie de se faire une bonne idée des individus. Le nombre de fragments dans ces catégories est très variable : 111 fragments pour le MeE (ex : le fragment A60b déjà cité) mais seulement 8 pour Acc2. Nous avons procédé à plusieurs lectures. La première, une lecture séquentielle, permet de dresser un portrait global. La seconde plus minutieuse exploite les métadonnées des fragments. Ainsi, la nature de la relation existant entre un témoin et le MeE peut-elle être prise en compte pour apprécier l'importance d'un propos.

#### 4.2 Contradictions versus stabilité dans les déclarations

Nous avons cherché s'il y avait des contradictions au sein d'une même catégorie, que ce soit des propos formulés par le même individu ou par des personnes différentes. Les contradictions les plus flagrantes portent sur la description des faits. Nous préférons citer ici deux petits exemples produits par la même personne où l'on constate une confusion certaine dans les dates. Nous avons pu également observer que des « erreurs » dans les dates citées par certains témoins sont partagées à l'identique par plusieurs personnes qui affirment pourtant ne pas s'être concertées. Dans D2a ci-dessous, nous avons une double référence à une année que nous désignons par *année\_1*. Dans D217c, nous retrouvons également une double référence temporelle mais cette fois avec une autre valeur *année\_2* et il n'y a pas de recouvrement entre les deux périodes citées.

D2a (lettre(Dr xxx), Acc2, jj/dd/aa) : Acc2 répète <i>que les fait se passaient</i> vers l'âge de xx ans, plusieurs fois (la dernière fois, elle devait être en classe de <nom d'une classe_1>, il y a donc 2 ans). D217c (Confr, MeE, Acc2, jj/mm/aa) : J'allais souvent en vacances chez eux. Les faits ont commencé alors que j'étais en classe de <nom d'une classe_2> à peu près. Ils se sont terminés en <i>année_2</i> .
--

Nous avons donc cherché, en parcourant cette catégorie, une explication à cette incohérence. Selon les dates caractérisant les fragments, on observe qu'après la déclaration D2a de Acc2, le MeE a invalidé l'accusation en soulignant (fragment D118g, non cité) qu'à l'époque mentionnée, il ne voyait plus Acc2 depuis x années. Acc2 corrige donc D2a par D217c pour resituer les accusations dans un intervalle de temps plausible.

Bien sûr, les contradictions les plus flagrantes se trouvent en confrontant les propos tenus par des personnes différentes. Cependant, la recherche de contradictions ne doit pas masquer la stabilité de certains propos. Nous les avons également étudiées. C'est le cas, par exemple, de la réfutation des accusations par MeE ou de certaines descriptions de Acc1.

#### 4.3 Les manques dans le dossier

Alors que notre démarche initiale s'inscrivait *de facto* dans une analyse des fragments extraits des textes donc présents, nous nous sommes demandé s'il n'y avait pas des manques dans le dossier. Il est, en effet, possible de travailler sur l'absence d'information dans une catégorie ou dans la globalité du dossier. On remarque par exemple que personne de l'accusation n'a formulé de propos sur la personnalité ou sur le caractère du MeE. Comme certains témoins évoquaient des relations difficiles entre MeE et la famille de Acc1 et 2, le juge aurait pu orienter ses questions pour mieux connaître la façon dont les deux parties accusation et défense se percevaient.

Nous nous sommes ensuite intéressé aux catégories contenant peu de fragments : nous avons notamment trouvé celle sur le caractère du père de Acc1 et Acc2. Seulement 18 fragments de textes évoquent le caractère du père contre 36 pour la mère. Certains de ces fragments évoquent un caractère effacé, un manque d'autorité. Nous avons alors cherché toutes les interventions du père dans le dossier. Il n'y a qu'une lettre de sa part mais elle ne fait que rapporter les propos de Acc1. Sinon, aucune déposition ni aucun interrogatoire. Il n'a donc jamais été invité à donner son avis.

#### 4.4 Analyse du déroulement de l'instruction

Convaincu que notre démarche appliquée à des dossiers en cours constituerait une aide pour le juge dans la phase d'instruction, il était légitime que nous nous demandions comment, dans une démarche classique, le juge d'instruction intervenait dans le dossier pour mener l'instruction. Nous avons donc défini une catégorie particulière qui nous a permis de collecter l'ensemble des interventions du juge d'instruction dans le dossier.

On constate que, malgré les risques soulignés par (Bensussan,1999), à aucun moment, le juge d'instruction ne remet en cause l'accusation. Les questions posées à Acc1 et 2 sont essentiellement des demandes de précision. L'analyse de cette catégorie reflète globalement une certaine passivité du juge et une adhésion totale aux propos de l'accusation. On observe également que phrases formulées par le juge d'instruction pour les demandes d'expertises (psychologiques...) contiennent des présupposés qui désignent clairement le mis en examen comme coupable. On peut s'en étonner même s'il est difficile d'estimer précisément l'impact de ces présupposés sur le compte-rendu des experts.

### 5 Conclusions et perspectives

Nous avons montré dans cet article que la méthodologie que nous avons mise en œuvre pour analyser le contenu d'un dossier d'instruction volumineux permet de repérer la cohérence ou les incohérences de certains propos, leur stabilité ou leur évolution. Elle s'avère également très efficace pour avoir une vision synthétique du dossier. Elle guide l'utilisateur pour demander de nouvelles recherches ou pour poser de nouvelles questions. Ce travail soulève quelques questions fondamentales.

Tout d'abord, une telle systématisme dans l'analyse d'un dossier est-elle souhaitable et les deux années que dure généralement une instruction ne permettent-elles pas au juge de faire cette synthèse objective ? Il est probable que non puisqu'on remarque que l'ordonnance finale de quelques pages que rend le juge d'instruction sur le dossier analysé ici contient des inexactitudes et attribue à un témoin des propos qu'il n'a pas tenus.

On peut également se demander si des informations essentielles, n'ont pas été oubliées au cours de la collecte des fragments. On ne peut le garantir formellement mais l'impact d'un ou de quelques oublis reste mineur. Notre démarche doit être perçue comme une aide faisant partie d'une procédure beaucoup plus complexe. Il ne faut pas interpréter trop rapidement les contradictions (*respectivement* la stabilité) des propos comme des éléments négatifs (*resp.* positifs). Nous soulignons simplement que ce sont des éléments qui ne peuvent pas être passés complètement sous silence et qu'ils peuvent alimenter une réflexion approfondie qui prendra alors le pas sur une intuition trop souvent sollicitée.

### Références

- Aas K., Eikvil L. (1999), Text categorisation: A survey. Technical report, Norwegian Computing Center, juin 1999.
- Bensussan P. (1999), *Inceste, le piège du soupçon*, Belfond, Paris.
- Bensussan P., Rault F. (2002), *La dictature de l'émotion. La protection de l'enfant et ses dérives*, Belfond, Paris.
- David R. (1997), *Le DAVIDO-CHAD. Le nouveau test psychologique : du dépistage à la thérapie*, Coll. Psychologiques, ISBN : 2-7384-5181-0.
- HandTest (1983), Western Psychological Services ed./Los Angeles.