# Une expérience de sémantique inférentielle

### Farid Nouioua, Daniel Kayser

Université Paris-Nord – LIPN {nouiouaf ; dk}@lipn.univ-paris13.fr

#### Résumé

Nous développons un système qui doit être capable d'effectuer les mêmes inférences que le lecteur humain d'un constat d'accident de la route, et plus particulièrement de déterminer les causes apparentes de l'accident. Nous décrivons les niveaux linguistiques et sémantiques de l'analyse, et les règles d'inférence utilisées par ce système.

Mots-clés : sémantique inférentielle, raisonnement non monotone, causalité.

#### **Abstract**

We are developing a system that aims to perform the same inferences as a human reader, on car-crash reports. More precisely, we expect it to determine the causes of the accident as they appear from the text. We describe the linguistic and semantic levels of analysis, and the inference rules used by the system.

**Keywords**: inferential semantics, non monotonic reasoning, causation.

#### 1. Introduction

La très grande majorité des tentatives pour formaliser la sémantique des langues naturelles se base sur l'idée que les propositions de la langue composent des unités de sens faisant référence à des entités d'un « univers de discours », et que le sens d'une proposition réside dans l'ensemble des conditions sur cet univers qui la rendent vraie (voir parmi de nombreuses autres références Chierchia et McConnell-Ginet, 1990 ou Chambreuil, 1998).

Les avantages et les inconvénients de ces approches sémantiques sont bien connus : précision et généralité des outils de représentation du sens, mais les opérations inférentielles étant contraintes par la validité logique ne permettent pas d'atteindre les conclusions « utiles » qu'un lecteur humain peut déduire du même texte. Ainsi, l'analyse sémantique du texte (1) ne permettra pas de répondre à une question, aussi évidente pour un lecteur humain, que : « le conducteur du véhicule B devait-il s'arrêter ? ».

Nous voulons construire un système capable d'inférer, sur un domaine restreint, les mêmes conclusions qu'un lecteur standard. La distinction usuelle entre sémantique et pragmatique nous paraissant plutôt une source d'embarras, nous la contournons en assignant aux différents niveaux linguistiques, et plus particulièrement à la sémantique, un but directement inférentiel. Ainsi, au lieu de considérer les unités lexicales comme référant à des objets, et la mise en phrase de ces unités comme un processus compositionnel visant à établir des conditions de vérité, nos hypothèses sont :

Les unités lexicales évoquent des inférences. L'idée d'une sémantique procédurale n'est pas nouvelle (voir par exemple Small (1981) ou le système inférentiel de Rieger (1975)

sur les idées de Schank); cependant, elle semble avoir été abandonnée au profit de théories mathématiquement plus élégantes, mais dont l'adéquation au langage est plus incertaine.

- Comprendre un texte, c'est essayer de satisfaire simultanément des contraintes émanant des différents niveaux de langue, ce qui ne peut se faire par une séquence de modules où chacun transmet au suivant les résultats acquis à son niveau.

Évidemment, il ne s'agit pas de prétendre construire en un temps forcément limité un système résolvant tous les problèmes! C'est pourquoi de nombreux éléments de notre travail n'ont que le statut de points de passage obligés : nos textes, comme tous les textes réels, nécessitent la résolution d'anaphores, l'interprétation des temps grammaticaux, des connecteurs à valeur argumentative, etc. Nous ne pouvons matériellement pas incorporer pour chacun de ces points les solutions les plus élaborées, et nous avons utilisé dans chaque cas des heuristiques simples qui nous paraissent convenir aux textes que nous traitons. De même, nous conservons l'architecture séquentielle de la plupart des systèmes de TAL, et limitons pour l'instant l'idée d'équilibre entre contraintes à un petit nombre de phénomènes de langue se situant dans un même niveau.

Néanmoins, contrairement à ces systèmes, nous n'adoptons pas l'approche selon laquelle la représentation sémantique découle directement de la représentation syntaxique et des sens attribués aux mots du texte. Cette vision suppose qu'il est possible d'une part d'attribuer des sens statiques aux mots et d'autre part de construire une représentation syntaxique correcte et complète des phrases. Dans notre idée, il est non seulement difficile, voire impossible d'atteindre ces objectifs, mais cette tentative est de plus inutile si notre but est d'approcher la compréhension humaine. Ainsi, sur le plan lexical, nous nous contentons de factoriser les entités lexicales en regroupant ensemble des mots pouvant déclencher le même genre de raisonnement dans certaines circonstances. Sur le plan syntaxique, nous nous limitons à extraire des relations de surface entre les entités lexicales du texte, relations qui servent également à déclencher des raisonnements.

Nous exposons dans cet article l'état d'avancement d'un système travaillant sur un domaine restreint, mais non-trivial : celui des accidents de la route. Notre but est que le système donne pour *cause*(s) de l'accident la ou les mêmes éléments qu'un lecteur ordinaire d'un constat amiable explicitant ses circonstances. Nous utilisons une conception de la causalité, développée dans (Kayser et Nouioua, 2005) et sur laquelle nous ne revenons pas ici, dans laquelle la cause est liée à la *norme* la plus spécifique qui a été violée.

Le plan de l'article est le suivant : la section 2 décrit les traitements qui élaborent, à partir du texte, des littéraux dans une logique du premier ordre réifié ne comportant que des prédicats jugés pertinents pour notre application. La section 3 montre comment ces prédicats déclenchent des inférences permettant d'extraire un « noyau », suffisant pour identifier ce qu'un lecteur humain considère comme étant la cause de l'accident. La section 4 met en perspective les résultats déjà obtenus et conclut l'article.

## 2. Les étapes « linguistiques »

#### 2.1. Le corpus

Nous avons collecté auprès d'une compagnie d'assurances un nombre significatif de constats amiables rédigés après un accident de la route. Nous ne conservons que les rapports qui permettent à un lecteur standard, indépendamment du schéma qui les accompagne parfois, de

déterminer ce qui, selon l'auteur du rapport, constitue la cause de l'accident<sup>1</sup>. Ce corpus a fait l'objet de nombreuses études depuis quelques années. On trouve par exemple dans la revue Tal (1994) différents travaux sur les aspects sémantiques de ces rapports.

Nous travaillons sur un échantillon de 60 rapports<sup>2</sup> jugés représentatifs de ce corpus. Leur longueur varie de 9 à 167 mots. Ils totalisent 129 phrases dont la longueur va de 4 à 55 mots ; 24 rapports n'ont qu'une seule phrase, le plus long en a 7. L'échantillon comprend 2256 mots occurrences, mais seulement 500 mots distincts, provenant de 391 entrées de dictionnaire.

Nous utilisons TreeTagger<sup>3</sup> pour étiqueter ce corpus. Ce logiciel généraliste n'étant pas conçu pour les spécificités de nos textes, il commet quelques erreurs systématiques, dont nous rectifions les plus courantes par un post-traitement; nous en profitons pour catégoriser plus finement quelques mots qui jouent par la suite un rôle important. En fin de compte, nous travaillons avec 41 catégories grammaticales. Le résultat de cette étape continue à comporter certaines erreurs ou imprécisions préjudiciables, mais que nous ne nous sommes pas permis de remettre en cause, pour ne pas rendre nos résultats dépendants d'une intervention manuelle sur nos données.

#### 2.2. Niveau syntaxique

Contrairement au choix adopté pour l'étiquetage, nous avons créé un outil *ad hoc* pour l'analyse syntaxique de notre corpus. Quelques essais d'utilisation des logiciels existants nous ont montré que le post-traitement serait ici nettement plus important, et comme il nous semblait (l'expérience a montré que c'était à tort!) que les tournures utilisées dans ces rapports étaient assez peu variées, nous avons pensé que l'effort de conception et de réalisation d'un tel outil ne serait pas énorme. Une autre raison de notre choix est la nature des résultats attendus de l'analyse syntaxique : les éléments structurels qui sont cruciaux ici, et les critères pour les obtenir, ne sont pas nécessairement ceux que l'on retient dans l'analyse de textes quelconques.

Notre méthode consiste à découper manuellement chaque phrase du corpus en « blocs » : le bloc Pré englobe, lorsqu'il y en a, les circonstants antéposés ; Princ contient la proposition principale, et le bloc Post, tout ce qui lui fait suite. La proposition principale est fragmentée en Groupe Nominal, Groupe Verbal, Complément Prépositionnel ; une grammaire de chacun de ces éléments est construite d'après le corpus, et on identifie ce qui, dans les blocs Pré et Post, est reconnu par ces grammaires locales ; une grammaire spécifique à chaque bloc est construite, toujours manuellement, en généralisant d'après les exemples. Le découpage de (1) donne d'abord (2), puis la proposition principale est découpée en (3) :

[Étant à l'arrêt au feu rouge]
$$_{Pr\acute{e}}$$
, [j'ai été percuté à l'arrière par le véhicule B] $_{Princ}$ , [son conducteur n'ayant pas réussi à s'arrêter] $_{Post}$ . (2)

$$[j']_{GN}$$
 [ai été percuté]<sub>GV</sub> [à l'arrière]<sub>CP</sub> [par le véhicule B]<sub>CP</sub> (3)

Les « blocs » Pré et Post sont alors analysés de façon analogue. Cette méthode aboutit à une grammaire qui, en raison notamment des problèmes de rattachement, est intrinsèquement ambiguë. Sur des phrases longues, l'ambiguïté peut avoir des conséquences catastrophiques (plusieurs dizaines de milliers d'analyses proposées pour une même phrase). Nous avons donc

<sup>&</sup>lt;sup>1</sup> On notera que cette tâche est assez différente de celles traitées d'une part par (Johansson *et al.*, 2005) : ces auteurs aboutissent à une représentation imagée de l'accident, d'autre part par (Després et Wolff, 2002) sur un corpus de rapports de gendarmerie.

<sup>&</sup>lt;sup>2</sup> L'exemple (1) de la section précédente en fait partie.

<sup>&</sup>lt;sup>3</sup> http://www.ims.uni-stuttgart.de/projekte/corplex/TreeTagger/DecisionTreeTagger.html

essayé de la réduire au maximum, en mettant en facteur ce qui pouvait l'être sans inconvénient pour les quelques relations syntaxiques que nous avons besoin d'extraire. Cet effort a réduit à un très petit nombre (mode < 8) les analyses d'une phrase; cependant, 8 phrases sur 129 ont plus de 100 analyses, le maximum étant 900, ce qui dégrade la performance moyenne (32,4 analyses par phrase).

La grammaire utilise 100 non-terminaux, et comprend 340 règles de réécriture. Nous l'avons testée sur 21 nouveaux rapports, contenant 56 phrases. La performance d'ensemble reste stable (mode très proche de 7; moyenne : 32,8). L'analyseur est écrit en C et les temps d'exécution sont très rapides (réponse immédiate à l'échelle humaine), même lorsque le nombre d'analyses atteint le millier.

Le but de l'analyse est de tirer de chaque phrase un nombre limité de relations syntaxiques. L'avantage d'avoir écrit un analyseur *ad hoc* apparaît ici pleinement : il suffit en effet d'orner une minorité de règles (155 / 340) par un très petit nombre d'actions (34) pour que chaque analyse s'accompagne de la production des relations souhaitées.

Comme on pouvait l'espérer, de nombreuses analyses produisent le même ensemble de relations, ce qui diminue considérablement le travail des étapes suivantes. L'exemple (1) est un des plus délicats en raison de nombreuses ambiguïtés syntaxiques de rattachement ; c'est pourquoi le nombre d'analyses est ici très élevé (180) ; mais seuls 60 ensembles de relations distincts sont passés à l'étape suivante, qui en éliminera beaucoup sur critères d'attachement sémantique. Parmi ces ensembles, on trouve notamment (on ajoute des numéros à quelques mots pour distinguer leurs différentes occurrences dans le texte) :

relation(PRÉ,être2,être1), support(être2,percuter), support(avoir,arrêter, sujet(être1,je), sujet(être2,je), sujet(avoir,conducteur), objet(avoir,s'), compl\_v (à1,être1,arrêt), compl\_v(à2,être2,arrière), compl\_v(par,être2,véhicule), compl\_n(au,arrêt,feu), qualif\_n(feu,rouge), qualif\_n(véhicule,B), qualif\_n(conducteur,son), qualif\_v(être1,PPRES), qualif\_v(être2,PASSÉ), qualif\_v(avoir,PPRES), qualif\_v(avoir,NEG)<sup>4</sup>

#### 2.3. Construction des littéraux sémantiques

On infère maintenant, de l'ensemble de relations de surface obtenu ci-dessus, une représentation « sémantique » du texte et on réalise ainsi le passage de l'espace de représentation purement linguistique manipulant des mots du langage à un espace sémantique qui, lui, manipule des concepts. Il s'agit de transformer progressivement les relations de surface issues du texte en un ensemble de littéraux sémantiques exprimant les informations qu'il évoque *explicitement*. Dans Kayser et Nouioua (2004), on trouve les détails du langage de représentation dont nous ne donnons ici que l'essentiel en raison de la place limitée dont nous disposons.

Ce langage du premier ordre « réifie » les noms de prédicats, c'est-à-dire qu'une relation binaire comme r(x,y) est représentée par le littéral *vrai(r,x,y)*. Les notions modales nécessaires à la détermination des causes, comme le fait pour un agent placé dans certaines circonstances de devoir ou d'être en mesure d'effectuer une action, s'exprimeront par doit(agent, action, circonstance) ou en mesure(agent, action, circonstance). Le rapport de

<sup>&</sup>lt;sup>4</sup> Ces littéraux portent un nom explicitant la relation grammaticale trouvée (par exemple qualif\_n (\_v) désigne une qualification du nom (du verbe) etc.). Nous employons « support » dans un sens élargi par rapport à Gaston Gross (Gross, 1999) : un support et son verbe sont présumés former un seul élément prédicatif, donc une relation peut s'adresser indifféremment au verbe ou au support.

l'accident décrit une séquence d'« états » (un état ne représente pas une situation « statique », mais un intervalle de temps durant lequel les prédicats jugés pertinents conservent une même valeur). L'argument *circonstance* des prédicats ci-dessus se réduit ainsi à l'identification d'un de ces intervalles.

Les littéraux du langage sont les prémisses de deux sortes de règles : les inférences strictes, traitées comme des implications, et les inférences par défaut au sens de Reiter (1980)<sup>5</sup>. Ces règles produisent des littéraux sémantiques, en réduisant à une même représentation logique des situations exprimées en langue par divers moyens lexicaux et/ou syntaxiques (synonymie, expressions anaphoriques, etc.).

#### Factorisation du lexique

L'intérêt des inférences vient essentiellement de leur généricité permettant à une règle de s'adapter à différentes situations. Pour assurer cette généricité, nous utilisons deux manières de regrouper des mots du lexique. La première consiste à rassembler dans une même classe d'équivalence les mots auxquels on attache en général le même sens dans le contexte de notre application. On utilise pour cela la relation  $val\_sem(x, y)$ , qui veut dire que y est la valeur sémantique du mot x dans ce contexte. La deuxième manière permet de regrouper dans un même type des mots partageant un certain nombre de caractéristiques communes qui suffisent à déclencher des inférences : type(x, y) exprime que y est le type du mot x.

#### Prétraitements des relations de surface

Des traitements préalables, procéduraux et inférentiels, sont effectués afin d'extraire des relations de surface, ce qui est nécessaire aux processus d'inférence des littéraux sémantiques.

La résolution des anaphores est un besoin qui s'impose dans les textes du corpus. Il s'agit d'un problème difficile dans le cas général. La résolution des références est effectuée manuellement, au stade actuel d'avancement de notre travail. Cependant, nous prévoyons à bref délai de l'automatiser, et nous pensons que la limitation de notre champ d'étude nous facilitera la tâche. On tirera profit des avancées réalisées dans cet axe de recherche (Mitkov, 2002) pour adapter une heuristique à notre contexte. L'algorithme devra produire la relation  $même\_ref(x, y)$  pour exprimer que « x et y réfèrent la même entité ». Dans notre exemple, on obtiendra :  $même\_ref(j', Auteur)$ ,  $même\_ref(son, véhicule)$ . Ce dernier résultat aboutira à ce que la relation  $qualif\_n(conducteur,son)$  soit équivalente à ce qu'aurait produit l'expression : conducteur du véhicule B. De plus, la métonymie très répandue qui assimile un conducteur à son véhicule se traduit par la règle : « si on a une relation qualif\\_n(x,y) où x est de type agent (type(x,agent)) et y est un symbole (A, B, C, ..), remplacer par y toutes les occurrences de x ainsi que les z ayant la même référence que x (même\\_ref(x,z)) ». Une première application de cette règle remplace véhicule et son par B, et une deuxième application de la même règle remplace conducteur par B.

Quelques expressions linguistiques courantes sont reconnues au préalable : ainsi, sur notre exemple, chaque occurrence de l'expression feu rouge est remplacée par l'entité « feu rouge ». D'autres prétraitements détectent et gèrent la voie passive. Enfin, nous

<sup>&</sup>lt;sup>5</sup> La notation A : B [C] représente le défaut A : B∧C / B qui exprime le fait que si A a été déduit, B le sera aussi sauf preuve du contraire (*i.e.* ¬B est déductible) ou blocage de cette règle (cas où ¬C est déductible).

procédons au remplacement du verbe support par le verbe supporté; ainsi, dans notre exemple le verbe avoir est remplacé par le verbe arrêter<sup>6</sup>.

#### Production de littéraux sémantiques « intermédiaires »

Le passage par un niveau intermédiaire est motivé par une raison méthodologique : il facilite l'écriture des règles d'inférence qui suivent en factorisant leurs prémisses et permet ainsi une meilleure lisibilité. À ce niveau, on fait apparaître également l'information temporelle dans les littéraux. Cette information est centrée sur les verbes et les prépositions, et figure en tant que paramètre dans un littéral intermédiaire sous la forme :  $ref_temp(x)$  qui indique « la référence temporelle liée au mot x ». Examinons quelques exemples de règles du niveau intermédiaire :

Le défaut (4) traite des verbes transitifs en regroupant dans une seule forme, plus proche de la forme finale voulue, le verbe, son sujet et son objet. Il signifie : si le sujet d'un verbe x est y, et son complément d'objet z, déduire que y vérifie le prédicat complexe (x,z) au temps référencé par x, sauf si x est à une forme négative.

```
sujet(x, y) \land objet(x, z) : vrai(combine(x, z), y, ref temp(x))[\neg qualif v(x, neg)] (4)
```

Des règles analogues permettent de traiter les cas des verbes intransitifs et des compléments prépositionnels. Voici les littéraux sémantiques intermédiaires obtenus pour la phrase (1) :

```
vrai(être1,Auteur,ref_temp(être1)),vrai(percuter,Auteur,ref_temp(percuter)),
¬vrai(arrêter,B,ref_temp(arrêter)),vrai(combine(arrêter,se),B,ref_temp(arrêter),
vrai(combine(combine(à1,être1),arrêt),Auteur,ref_temp(à1)),
vrai(combine(combine(à2,percuter),arrière),Auteur,ref_temp(à2)),
vrai(combine(combine(par,percuter),B),Auteur,ref_temp(par)).
```

#### Détermination des noms des littéraux sémantiques, et calcul des relations temporelles

Les règles de cette étape permettent d'une part de fixer définitivement les arguments des littéraux sémantiques, et d'autre part de générer un ensemble de relations entre les références temporelles. Deux types de relations sont considérées : Préc(T1, T2) qui veut dire que T1 précède T2 et Simul(T1, T2) qui exprime le fait que T1 et T2 sont simultanés. Le nombre de cas de figure à considérer pour nos textes semble assez réduit, ce qui explique que nous n'ayons pas besoin de toute la panoplie d'outils déployés par exemple par Person (2004). Considérons le fonctionnement de quelques règles sur notre exemple :

```
type(\texttt{L},agent) \land val\_sem(\texttt{X},\grave{a}) \land val\_sem(\texttt{V},\^{e}tre) \land val\_sem(\texttt{N},arr\^{e}t) \land vrai(\texttt{V},\texttt{L},ref\_temp(\texttt{V})) \land vrai(combine(combine(\texttt{X},\texttt{V}),\texttt{N}),\texttt{L},ref\_temp(\texttt{X})) : vrai(arr\^{e}ter,\texttt{L},ref\_temp(\texttt{V}))  (5)
```

Cette règle permet d'inférer (avec L = Auteur) à partir de « Étant à l'arrêt..., j'... », le littéral :  $vrai(arrêter, Auteur, ref\_temp(être))$ . Tandis que la règle (6) infère (avec L = Auteur,  $Z = a^2$ , V = percuter, N = arrière) les deux littéraux :  $vrai(combine(position\_choc, arrière)$ , Auteur, Percuter Percut

 $prep(Z) \land type(L, v\'ehicule) \land type(N, position) \land val\_sem(V, heurter) \land vrai(combine(combine(Z, V), N), L, ref temp(Z)) \land voie(V, passive) :$ 

<sup>&</sup>lt;sup>6</sup> Une liste de verbes supports est établie à priori. Des traitements plus compliqués peuvent être envisagés. Par exemple, le support **oublier** introduit une négation sur le verbe supporté ; de même pour le support **empêcher** qui en plus affecte son objet comme sujet au verbe supporté...

$$vrai(combine(position\_choc, arrière), \ L, \ ref\_temp(\ V)) \land simul(ref\_temp(\ V), \ ref\_temp(\ Z))$$
 (6)

Des règles de même nature infèrent le reste des littéraux.

#### Calcul des paramètres temporels : produire la version finale des littéraux sémantiques

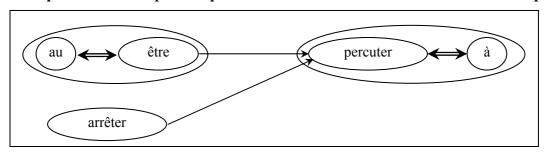


Figure 1. Graphe temporel du texte (1)

(« au » est la préposition du groupe « au feu rouge », « à » est celle du groupe « à l'arrêt »)

La dernière tâche à effectuer avant de trouver la version finale des prédicats sémantiques consiste à ordonner les références temporelles. Une méthode générale pour ce faire est de modéliser les relations  $pr\acute{e}c$  par un graphe orienté G dont les nœuds sont les références temporelles. (T1, T2) est un arc de G si et seulement si on dispose de la relation  $pr\acute{e}c(T1, T2)$ . Le graphe obtenu est, bien entendu, acyclique (il est impossible de trouver deux instants distincts où chacun est situé avant l'autre!). La figure 1 représente le graphe correspondant à notre texte. On décompose le graphe G en niveaux. Les références temporelles appartenant au  $i^{\acute{e}me}$  niveau du graphe sont remplacées par la valeur entière i. Enfin, on utilise la relation simul pour attribuer les bonnes valeurs aux références temporelles restantes. Dans notre exemple, la décomposition du graphe permet d'obtenir:

$$ref temp(\hat{e}tre) = ref temp(arr\hat{e}ter) = 1; ref temp(percuter) = 2.$$

Les relations :  $simul(ref\_temp(\hat{e}tre), ref\_temp(au))$  et  $simul(ref\_temp(percuter), ref\_temp(\hat{a}))$  permettent d'en déduire :  $ref\_temp(au) = 1$  et  $ref\_temp(\hat{a}) = 2$ . La liste des littéraux sémantiques obtenus sera ainsi :

vrai(arrêter, Auteur, 1), vrai(feu\_rouge, Auteur, 1), ¬vrai(arrêter, B, 1), vrai(combine(heurter, Auteur), B, 2), vrai(combine(position\_choc, arrière), Auteur, 2).

## 3. Les étapes « sémantiques »

Le raisonnement sémantique que nous devons entreprendre sur la représentation ainsi obtenue a pour but de trouver la cause de l'accident. Les règles employées sont basées sur nos connaissances sur les normes du domaine de la route et permettent d'enrichir les littéraux sémantiques résultant des traitements linguistiques par de nouveaux littéraux incorporant des informations *implicites* sur l'accident. Bien que le texte ne les énonce pas explicitement, ces informations sont indispensables à sa compréhension et elles font partie de ce qu'un lecteur humain infère systématiquement à la lecture d'un texte (voir l'exemple (1) au § 1.). Le processus de raisonnement sémantique converge vers un noyau<sup>7</sup> d'un nombre restreint de

<sup>&</sup>lt;sup>7</sup> Les prédicats du noyau concernent les propriétés : arrêt, contrôle, démarrer, reculer, rouler\_lentement et combine(cause perturbation anormale, X) *i.e.* X est une cause de perturbation anormale.

littéraux. Ces prédicats sont choisis de manière à ce qu'ils suffisent pour exprimer les différentes causes possibles exprimées dans les réponses d'un lecteur humain ordinaire et qu'ils .permettent d'imposer un critère d'arrêt aux inférences à un niveau de granularité qui correspond bien à ce qu'on attend généralement de la réponse d'un lecteur humain.

La cause recherchée correspond à une violation d'une norme du domaine appelée aussi anomalie. Si plusieurs anomalies sont présentes, on distingue la « *vraie anomalie* », qui explique le mieux l'accident, des anomalies qui en résultent. Une vraie anomalie est détectée notamment si « à un instant T, un agent A doit atteindre un effet<sup>8</sup> E, qu'il est en mesure de le faire mais qu'à l'instant T+1, un effet E' incompatible avec E est vérifié » (règle (7)) voir (Kayser et Nouioua 2004 et 2005) pour plus de détails).

$$doit(E,A,T) \land en \ mesure(E,A,T) \land vrai(E',A,T+1) \land incompatible(E,E') \rightarrow vraie \ An$$
 (7)

#### 3.1. Réduction des littéraux sémantiques aux littéraux noyaux

Pour illustrer la nature des inférences de ce niveau, prenons deux exemples de règles : la règle stricte (8) exprime le fait que : « Si w heurte v à un instant T, alors w n'est pas à l'arrêt à cet instant T ». Elle permet de déduire le littéral : ¬vrai(arrêter, B, 2). Le défaut (9) exprime le fait que : « En général, s'il y a un choc entre v et w à l'instant T et que la position du choc de v est l'arrière, alors w était le suivant de v dans une file à l'instant T-1. Cette inférence est bloquée si w n'a pas le contrôle à l'instant T-1 ». Ce défaut permet d'inférer le littéral : vrai(combine(suiv, Auteur), B, 1).

Des règles de même nature infèrent les prédicats :

vrai(combine(choc, Auteur), B, 2), vrai(combine(choc, B), Auteur, 2), vrai(combine(obstacle, Auteur), B, 1), vrai(combine(obstacle, B), Auteur, 1).

$$vrai(combine(heurter, V), W, T) \rightarrow \neg vrai(arrêter, W, T)$$
 (8)

$$vrai(combine(choc, V), W, T) \land vrai(combine(position\_choc, arrière), V, T) : vrai(combine(suiv, V), W, T-1) [vrai(contrôle, W, T-1)]$$
 (9)

#### 3.2. Détection de la cause à partir du noyau

Une première règle, exprimant le fait que « On doit à tout instant éviter les obstacles s'ils se présentent », permet d'inférer le devoir de chacun des agents Auteur et B d'éviter l'autre. Le défaut (10) exprime que le meilleur moyen d'éviter un obstacle est de s'arrêter (sauf si l'obstacle nous suit, ou si on est déjà à l'arrêt, ou quelques autres cas). Son application permet d'inférer doit(arrêt, B, 1). Ce devoir n'est pas inféré pour Auteur car le défaut dans ce cas est bloqué par vrai(combine(suiv, Auteur), B, 1).

La règle (11) permet d'inférer la capacité d'un agent. Sa signification est que : « v est en mesure à l'instant v d'atteindre un effet v, si et seulement s'il existe une action Act qui est une raison potentielle pour v et qui est disponible pour v à l'instant v :

$$\begin{aligned} \textit{doit}(\textit{combine}(\textit{\'eviter}, \, \texttt{W}), \, \texttt{V}, \, \texttt{T}) & \land \textit{vrai}(\textit{combine}(\textit{choc}, \, \texttt{W}), \, \texttt{V}, \, \texttt{T}+1) : \textit{doit}(\textit{arrêt}, \, \texttt{V}, \, \texttt{T}) \\ & [ \neg \textit{vrai}(\textit{combine}(\textit{suiv}, \, \texttt{V}), \, \texttt{W}, \, \texttt{T}), \, \neg \textit{vrai}(\textit{arrêt}, \, \texttt{V}, \, \texttt{T}), \, \neg \textit{doit}(\textit{roule}\_\textit{lentement}, \, \texttt{V}, \, \texttt{T}), \\ & \neg \textit{doit}(\textit{non}(\textit{reculer}), \, \texttt{V}, \, \texttt{T}-1), \, \neg \textit{doit}(\textit{non}(\textit{d\'emarrer}), \, \texttt{V}, \, \texttt{T}-1), \\ & pr\'evisible(\textit{combine}(\textit{obstacle}, \, \texttt{W}), \, \texttt{V}, \, \texttt{T}) \, ] \end{aligned}$$

<sup>&</sup>lt;sup>8</sup> Nous utilisons une « ontologie » qui distingue *a priori* des noms d'action Act (ce qu'un agent peut volontairement décider d'entreprendre) et des noms d'effet E (le résultat anticipé d'une action) ; la connexion entre les deux s'effectue par la relation raison\_pot(Act,E) (vouloir obtenir E est une raison potentielle pour entreprendre Act).

$$en\_mesure(E,V,T) \leftrightarrow action(Act) \land effet(E) \land raison\_pot(Act, E) \land disponible(Act,E,V,T)$$
 (11)

L'ensemble des actions, des effets et des raisons potentielles sont prédéterminés statiquement, et on a par exemple : *raison pot(freiner, arrêter)*.

Par défaut, les actions sont disponibles. Ce défaut est inhibé en présence d'un certain nombre d'exceptions (absence de contrôle, présence d'un événement non maîtrisable, ...). Aucune de ces exceptions n'est présente dans notre cas. Le défaut s'applique donc et donne : disponible(freiner, arrêter, B, 1). Ce qui nous permet d'inférer : en mesure(arrêter, B, 1).

Les littéraux : *doit(arrêter, B, 1)*, *en\_mesure(arrêter, B, 1)* et *vrai(arrêter, B, 2)* déclenchent la première forme d'une vraie anomalie (7) et déduisent : *Vraie\_An*, ce qui met un terme à la recherche de la cause. Celle-ci est exprimée comme suit :

« Le véhicule B avait à l'instant 1 le devoir de s'arrêter afin d'éviter le choc, mais il n'a pas respecté son devoir car à l'instant 2, il n'était pas à l'arrêt ».

### 4. Discussion, conclusion et perspectives

Le système est en cours d'implémentation. Nous avons utilisé pour cela, le langage SMODELS<sup>9</sup> basé sur la théorie des modèles stables (Gelfond et Lifschitz, 2004). Chaque modèle stable trouvé par SMODELS est formé de l'ensemble des littéraux appartenant à une extension de la théorie des défauts sous-jacente. La partie du raisonnement qui cherche la cause de l'accident à partir des littéraux sémantiques est complètement testée. Avec environ 200 règles, le système trouve, pour chacun de nos 60 textes, un seul modèle stable contenant les littéraux nécessaires à l'expression de la cause de l'accident. Le temps d'exécution varie d'un texte à l'autre, mais ne dépasse pas 30 secondes.

Comme nous avons « traité à la main » les 60 rapports de l'échantillon en supposant résolues les étapes menant aux littéraux sémantiques, nous savons que les causes trouvées par notre système seront bien celles que nous espérions obtenir, dès que les dernières difficultés linguistiques seront résolues. Il est évident qu'elles le seront pour notre échantillon, au prix d'un traitement *ad hoc* s'il le faut

Il est non moins évident qu'un ajout de nouveaux rapports dégradera les performances de notre système, ne serait-ce qu'en raison de mots et de tournures qui ne figurent pas dans l'échantillon. Ce qui est difficilement évaluable actuellement, c'est l'ampleur de cette dégradation, et surtout l'effort à fournir pour y remédier. Notre grammaire est assez fragile, et il faudra peut-être recourir à des analyseurs généralistes, surtout si ceux-ci s'améliorent. Nous pensons au contraire que les autres étapes : la construction des littéraux sémantiques, leur réduction à un noyau, et l'inférence de la cause, sont assez robustes. Cette conjecture ne tardera pas à être vérifiée ou infirmée.

Supposons qu'elle soit vérifiée : pour que la valeur de notre travail dépasse la simple prouesse d'ingéniosité, il faudra utiliser la même approche dans un autre domaine. Si elle fait ses preuves, prouvant une certaine généricité, en fournissant des inférences analogues à celles des

<sup>&</sup>lt;sup>9</sup> SMODELS travaille sur le résultat d'un autre logiciel : LPARSE qui entre autres instancie les variables afin de produire des règles propositionnelles. SMODELS et LPARSE sont disponibles sur le Web à l'adresse http://www.tcs.hut.fi/Software/smodels/

humains dans différentes spécialités, on pourra envisager d'élargir son champ d'application, et collecter une fraction de plus en plus importante des normes qui guident le raisonnement de sens commun. Cette démarche nous semble plus raisonnable que celle consistant, comme CYC (Lenat et Guha, 1990), à attaquer de front l'ensemble des connaissances humaines.

Simultanément, il serait intéressant de faire interagir un plus grand réseau de contraintes, afin que les extensions trouvées par le système de raisonnement (SMODELS ou un autre) prennent en compte les défauts utilisés à tous les niveaux. Ceci permettrait d'aboutir pour chaque texte à l'interprétation qui satisfait simultanément le mieux l'ensemble des contraintes identifiées, qu'elles soient orthographiques, morpho-lexicales, syntaxiques, ou sémantico-pragmatiques.

#### 5. Remerciements

Nous exprimons nos remerciements à la M.A.I.F. qui nous a donné libre accès à un grand nombre de constats d'accident, ainsi qu'à Françoise Gayral et à Thierry Poibeau et aux relecteurs anonymes de TALN pour leurs commentaires critiques sur des versions antérieures de cet article.

#### Références

- CHAMBREUIL M. (dir.) (1998). Sémantiques. Hermès, Paris.
- CHIERCHIA G., MCCONNELL-GINET S. (1990). *Meaning and Grammar. An Introduction to Semantics*, MIT Press, Cambridge, London.
- DESPRÉS S., WOLFF M. (2002). Modélisation et formalisation de l'activité cognitive de l'expertise des accidents : vers un développement d'un Système d'Aide à l'Analyse des Accidents (S3A). Rapport final du projet cognitique n°21.
- GELFOND M., LIFSCHITZ V. (2004). « The Stable Model Semantics for logic programming ». In *Proceedings of the 5<sup>th</sup> International Conference on Logic Programming*: 1070-1080.
- GROSS G. (1999). « Verbes supports et conjugaison nominale ». In *Revue d'études francophones* 9 : 70-92.
- JOHANSSON R., BERGLUND A., DANIELSSON M., NUGUES P. (2005). « Automatic Text-to-Scene Conversion in the traffic Accident Domain ». In *Proceedings of the 19<sup>th</sup> IJCAI*: 1073-1078.
- KAYSER D., NOUIOUA F. (2004). « Representing knowledge about norms ». In *Proceedings of the 16<sup>th</sup> ECAI Conference*: 363-367.
- KAYSER D., NOUIOUA F. (2005). « About Norms and Causes ». In *International Journal on Artificial Intelligence Tools. Special Issue on FLAIRS 2004* 14 (1/2): 7-23.
- LENAT D., GUHA R. (1990). Building Large Knowledge-Based Systems. Addison-Wesley.
- MITKOV R. (2002). Anaphora Resolution. Pearson Education.
- Person C. (2004). Traitement automatique de la temporalité du récit : implémentation du modèle linguistique SdT. Thèse de Doctorat, Université de Caen.
- REITER R. (1980). « A Logic for Default Reasoning ». In Artificial Intelligence 13 (1/2): 81-132.
- RIEGER C.J. (1975). « Conceptual Memory and Inference ». In R.C. Schank, *Conceptual Information Processing*. North-Holland Publishing Co, Amsterdam: 157-288.
- SCHANK R.C. (1975). Conceptual Information Processing. North-Holland Publishing Co, Amsterdam.
- SMALL S. (1981). « Viewing word expert parsing as a linguistic theory ». In *Proceedings of the 7<sup>th</sup> IJCAI*: 70-76.

FARID NOUIOUA, DANIEL KAYSER 256 TAL (1994). Numéro spécial Approches sémantiques, Revue TAL 35 (1).