

L'analyse morphologique des réponses d'apprenants

Alexia Blanchard

LIDILEM – Université Stendhal, Grenoble

Alexia.Blanchard@u-grenoble3.fr

Résumé. Nous présentons une approche empirique de l'évaluation automatique des réponses d'apprenants au sein d'un système d'Apprentissage des Langues Assisté par Ordinateur (ALAO). Nous proposons la mise en place d'un module d'analyse d'erreurs attestées sur corpus qui s'appuie sur des techniques robustes de Traitement Automatique des Langues (TAL). Cet article montre la réalisation d'un module d'analyse de morphologie flexionnelle, en situation hors-contexte, à partir d'un modèle linguistique existant.

Abstract. We present an empirical approach to the automated evaluation of learner's answers in a CALL system (Computer Assisted Language Learning). We suggest the realization of an error parsing module using NLP techniques (Natural Language Processing). The errors stem from a language learners corpus. This article describes the implementation, from an existing linguistic model, of an inflectional context-free morphology parser.

Mots-clés : TAL, ALAO, détection d'erreurs, morphologie flexionnelle, rétroaction(s).

Keywords: NLP, CALL, errors detection, inflectional morphology, feedback.

1 TAL et analyse des réponses en ALAO

L'Apprentissage des Langues Assisté par Ordinateur (ALAO) a pour but le développement d'outils et de ressources destinés à l'apprentissage des langues. Parmi ces outils, nous trouvons les logiciels éducatifs qui proposent un aspect interactif (l'apprenant interagit avec le système), et également, en théorie, un apprentissage individualisé, personnalisé et autonome. Deux apprenants peuvent acquérir les mêmes connaissances à leur rythme, avec un parcours adapté au sein du logiciel. Il existe une typologie de ces logiciels (Lancien, 1997 ; Wyatt, 1988) : les logiciels d'exploration (l'apprenant simule une situation dans le but de rechercher des informations sur le réseau), les logiciels de référence (l'apprenant dispose d'outils pour l'aider dans sa recherche d'informations comme des encyclopédies) et les logiciels de structure (l'apprenant est soumis à une autoévaluation). Nous nous intéressons ici à ce dernier type de logiciels, qui proposent des exercices, généralement structuraux, et plus particulièrement à l'évaluation automatique de ces exercices, qui constitue un des critères de qualité du « potentiel d'utilisation » d'un logiciel d'apprentissage selon Nielsen (1993, p.20) : *« Errors messages should be expressed in plain language (no codes), precisely indicate the*

problem, and constructively suggest a solution¹ ».

Cette évaluation implique la détection des erreurs commises par l'apprenant et leur analyse afin de produire des rétroactions adaptées (feed-back). Certains se sont demandés s'il était possible d'utiliser des correcteurs orthographiques et grammaticaux existants pour corriger les erreurs de l'apprenant. Une étude (Cordier-Gauthier, Dion, 2002) a démontré que ces correcteurs ont tendance à surdétecter par rapport à la correction d'enseignants. De plus, l'analyse des erreurs propose plusieurs solutions pour une même forme, ce qui limite leur utilisation dans un dispositif d'ALAO.

L'incapacité des systèmes d'ALAO à prendre en compte les propriétés intrinsèques à une langue restreint leurs possibilités. Les principales critiques de ces systèmes restent leur fermeture (contenus des exercices prédéfinis et figés), une détection d'erreurs fondée sur de simples comparaisons de chaînes (pattern-matching), et par conséquent des rétroactions / feed-back pédagogiquement peu adaptés à l'apprenant, du type « vrai/faux ». Ces aspects font défaut depuis toujours dans les travaux en ALAO (Antoniadis et al., 2005b).

Nous pensons que l'intégration d'outils de Traitement Automatique des Langues (TAL) peut permettre de débloquent cette situation et d'améliorer l'analyse des réponses (Antoniadis et al., 2006). Le TAL (Traitement Automatique des Langues) est au carrefour entre linguistique et informatique, et ne considère plus la langue comme une simple suite de caractères, mais comme un système à deux niveaux (sens et forme) (Fuchs et al., 1993).

L'utilisation du TAL dans la conception de systèmes d'ALAO n'est certes pas une idée nouvelle. Certains projets comme Freetext, ont développé un logiciel d'ALAO pour des apprenants du français (Granger et al., 2001). Pour ce faire, ils se sont fondés sur l'analyse du corpus FRIDA (French Interlanguage DATABASE), qui a abouti à un étiquetage et une typologie des erreurs. Cette dernière a ensuite permis la création d'un outil de détection d'erreurs orthographiques, syntaxiques et sémantiques. Une évaluation effectuée en 2003 sur 120 phrases a permis de comparer le prototype de FreeText avec le correcteur de Microsoft Word® 2000 (L'Haire, Vandeventer, 2003). Les résultats montrent que le système FreeText est relativement plus performant que Word®. Toutefois, les auteurs s'accordent pour mettre en évidence la surdétention d'erreurs de la part du système Freetext, phénomène qui peut complètement perturber l'apprenant en situation d'apprentissage.

C'est pourquoi nous préférons privilégier une méthode empirique (1) en utilisant des outils fiables du TAL (2) en réalisant un module d'analyse d'un certain type d'erreurs dans le but, à long terme, de réaliser un système plus complet, intégrable dans un système d'ALAO (3) en traitant des erreurs issues d'un corpus.

Un premier travail a donc consisté à élaborer un module d'analyse qui prend en entrée une forme simple (nom, adjectif ou verbe) et qui analyse ses traits morphologiques afin de détecter une éventuelle erreur de morphologie flexionnelle. La sortie propose un ou plusieurs diagnostic(s) pour une même forme, erronée ou non. Par exemple, la forme *place* est analysée comme une forme erronée du verbe placer à la 1^{ère} personne du singulier de l'indicatif, du subjonctif et à la 3^{ème} personne du singulier de l'indicatif, et du subjonctif (4 diagnostics).

Nous verrons dans un premier temps la méthodologie adoptée pour définir les propriétés de cet analyseur, puis nous décrirons les travaux menés au CRISS pour l'analyse et la génération

¹ « Les messages d'erreurs doivent être écrits en langage naturel (pas de codes), ils doivent indiquer précisément le problème, et suggérer une solution qui aidera l'apprenant à rectifier son erreur ».

morphologique dans un cadre autre que l'ALAO ; travaux que nous avons repris et adaptés à notre sujet. Enfin, nous montrerons les premiers résultats du prototype réalisé.

2 Positionnement

Le domaine de l'ALAO est à la croisée de plusieurs disciplines : didactique des langues, linguistique et TAL. La conception d'un système d'ALAO se doit, à notre avis, de prendre en compte les aspects de ces différentes disciplines.

En ce qui concerne l'évaluation automatique des productions écrites de l'apprenant, il est reconnu qu'un système d'ALAO ne peut être didactiquement valide que s'il est capable d'analyser correctement ces productions afin de ne pas générer des rétroactions erronées (Rézeau, 2004). Une maîtrise incomplète de l'analyse pourrait impliquer un apprentissage partiellement voire complètement biaisé.

Pour ce faire, nous avons préféré brider dans un premier temps notre analyseur, en considérant les contraintes des trois domaines concernés. Notre but n'est pas de proposer une analyse exhaustive des réponses d'apprenants en production libre. Il faut être conscient des fortes contraintes didactiques d'un système d'ALAO. En effet, une telle analyse doit permettre de générer automatiquement une, et une seule explication de chaque erreur pour que l'apprenant puisse comprendre et corriger ses lacunes.

Se posent alors plusieurs problèmes : Quelles informations extraites de l'analyse permettent réellement de prédire une explication quant à l'erreur ? Devons-nous traiter toutes les erreurs théoriquement possibles ou devons-nous cibler les erreurs les plus fréquentes chez un apprenant du français ?

Pour répondre à ces questions, nous avons choisi de nous appuyer sur l'outil TAL le plus fiable aujourd'hui, en l'occurrence l'analyse morphologique flexionnelle :

« La question des flexions grammaticales est, depuis longtemps clairement maîtrisée [...] », (Fuchs et al., 1993, p. 102).

Toutefois, l'analyse morphologique comme nous la concevons en TAL repose sur un texte correctement orthographié. Une telle analyse est donc différente d'une analyse morphologique des réponses d'apprenants qui a pour but la génération d'une rétroaction. Pour réaliser un tel analyseur, il nous a donc fallu effectuer un certain nombre de choix :


• **Les types d'erreurs** : Si nous nous penchons sur les études antérieures en didactique des langues, des erreurs fréquentes de morphologie flexionnelle se dégagent :

- Erreurs de surgénéralisation (Fayol, 2001) : cette notion dénote le fait que les apprenants ont tendance à appliquer la règle d'accord du pluriel sur une autre catégorie (exemple : *les attitudes*).
- Erreurs d'omission de flexions du nombre (Astolfi, 1997).
- Erreurs de généralisation (Ågren, 2005) : la généralisation concerne les erreurs d'utilisation d'une flexion d'un type de nom par exemple, sur un autre type de nom (exemple : *les lieux*).

Notre modélisation s'appuie sur ces tendances, mais également sur des erreurs extraites du corpus FRIDA² mis à notre disposition dans le cadre du projet Idill³.

- **Le / les diagnostic(s) :** Nous différencions les notions de diagnostic et de rétroactions. Les rétroactions sont les explications proposées à l'apprenant pour lui expliquer son erreur, alors que les diagnostics sont l'ensemble des informations qui résultent de l'analyse morphologique, sachant que plusieurs diagnostics peuvent être associées à une même forme. Nous préférons rester prudents en conservant toutes les interprétations possibles pour une même forme, afin de ne pas risquer de biaiser la qualité de la rétroaction générée à partir de ce / ces diagnostic(s). Chaque forme sera ainsi associée à son lemme, sa catégorie syntaxique, ses traits morphologiques, le type d'erreur morphologique (notre analyseur est capable d'analyser les formes correctes comme les formes erronées). Si nécessaire, la désambiguïsation pourra être faite à un niveau didactique (via le modèle de l'apprenant, le domaine d'apprentissage, etc.).

- **L'algorithme d'analyse :** A partir des deux premiers points énoncés ci-dessus (ce que prend en entrée l'analyseur et ce qu'il génère en sortie), nous pouvons schématiser le fonctionnement du module réalisé de la façon suivante :



Exemple :

milieus → milieu + s → milieu (Nom) + flexion nombre → Au pluriel, le nom *milieu* ne prend pas un « -s »
 erreur : surgénéralisation

Schéma 1 : Algorithme d'analyse du module et exemple

3 Analyse morphologique des réponses d'apprenants

3.1 L'analyse morphologique en TAL

En TAL, l'analyse morphologique s'appuie sur les règles de formation des mots révélés par les travaux en linguistique. Elle consiste, à partir d'un texte source à extraire des informations pour chaque mot.

Nous trouvons trois écoles principales d'analyse morphologique (Fuchs et al., 1993) qui proposent différentes solutions pour un même problème : comment découper une forme fléchie en base et flexion(s) dans le but de générer un maximum d'informations:

² Tous les exemples de formes erronées cités dans l'article sont issus de ce corpus.


³ Integrated Digital Language Learning (<http://www.idill.org>). Ce projet a été développé dans le cadre du réseau d'excellence européen Kaleidoscope (<http://www.no-kaleidoscope.org>).

- **Les dictionnaires de formes fléchies** : Cette façon de procéder a l'avantage de ne demander que peu de traitements informatiques. Elle consiste à lister toutes les formes fléchies des mots du français dans un dictionnaire. Il n'y a donc pas de découpage de forme.
- **Les automates à états finis** : un ensemble d'automates définit les combinaisons autorisées entre bases et affixes contenues dans un dictionnaire. Une forme est validée si elle est acceptée par un automate (e.g. *veuve*-> *veu* + *ve*).
- **Le modèle à deux niveaux** : La grammaire du modèle à deux niveaux permet le découpage d'une forme en prenant en compte ces variations phonologiques. L'analyse du mot *veuve* est donc possible, et ce mot est reconnu comme une forme fléchiée de la base *veuf*, à laquelle sont rattachées des informations morphologiques (e.g. *veuve*-> *veuf* + *e*).

Pour notre problématique, la méthode utilisée doit obligatoirement permettre une interprétation fine et pertinente des informations morphologiques dans le but de proposer des rétroactions de qualité. L'utilisation de dictionnaire ne semble pas appropriée car elle ne permet pas de détecter une erreur. Par exemple, *lieus* ne peut être analysé car c'est une entrée inconnue. L'utilisation des automates à états finis limite l'interprétation des erreurs. Si nous prenons l'exemple de *carnavaux*, cette technique découpera cette forme en *carnav* + *aux*. Ce découpage ne permet pas d'extraire d'informations pertinentes pour notre sujet.

L'analyse à deux niveaux semble donc la plus pertinente pour notre problématique. Toutefois, cette méthode n'est valable que pour les formes correctement orthographiées. Une réadaptation de celle-ci est donc nécessaire pour l'analyse d'erreurs.

Le modèle développé au CRISS (Lallich-Boidin et al., 1990) suit le principe du modèle à deux niveaux et nous semble donc adapté et adaptable pour l'analyse d'erreurs morphologiques car il se fonde sur un découpage des formes qui permet une interprétation linguistique des bases et flexions extraites. Voici un exemple d'analyse avec la forme *bones* :



Il peut découper la forme *bones* mais n'est certes pas capable d'interpréter cette analyse du simple fait qu'il n'a pas été conçu pour reconnaître des formes erronées. Toutefois, le découpage proposé nous permet de modéliser une interprétation de forme erronée.

3.2 L'analyseur morphologique du CRISS

3.2.1 Description générale

Dans les années 90, une équipe du CRISS a développé un analyseur du français en collaboration avec A. Berrendonner (1990). Il prend en entrée un texte écrit, auquel il applique une analyse morphologique et syntaxique, pour en ressortir une représentation logique. Le système a une architecture modulaire, c'est-à-dire qu'analyse morphologique et analyse syntaxique sont séparées. Ceci nous permet d'utiliser facilement les données et algorithmes relatifs à l'analyse morphologique.

Le modèle du CRISS réalise un découpage interprétable de forme (en base et flexion(s)) dans le sens où il utilise les propriétés linguistiques intrinsèques à la langue pour ce qui concerne la formation flexionnelle des mots. Ces propriétés concernent entre autres la place d'apparition des flexions (e.g. base + flexion genre + flexion nombre)).

Ce modèle original utilise un dictionnaire de bases, qui pour chaque base recense le lemme

correspondant, la catégorie syntaxique de ce lemme, le nom du modèle auquel il est associé (dans le cas d'un lemme variable). Voici un exemple d'entrées lexicales :

frère (base), **frère** (lemme), **F** (Catégorie⁴), **coup** (Modèle de flexion)

Les modèles de flexions permettent de décrire les phénomènes de variations flexionnelles pour un lemme donné. Si nous reprenons l'exemple du lemme *frère*, voici la description du modèle associé :

coup [masculin, singulier] [Ø] [s] masculin, pluriel

Le nom du modèle associé à *frère* est *coup*. La première paire de crochets signifie que la base associée au modèle *coup* est au masculin singulier, la seconde paire vide montre que cette base n'accepte pas de flexion du féminin et qu'aucune flexion n'est nécessaire pour former le masculin à partir de la base, et la troisième paire de crochets signifie que la base *coup* fait son pluriel en -s.

Dans le souci de privilégier les calculs aux données⁵, l'équipe du CRISS a décidé de ramener au maximum les exceptions aux cas généraux. Cette opération s'effectue à l'aide de règles dites de *régularisations*. Ces dernières ont pour but de réduire le nombre de bases pour un même mot, et donc le nombre d'entrées du dictionnaire. Elles permettent également de diminuer le nombre de flexions et de modèles.

Il existe deux types de régularisations :

- les régularisations portant sur la forme : elles consistent à remplacer le suffixe d'une forme par un autre suffixe, avant le découpage de celle-ci.
- les régularisations portant sur la base : elles interviennent après le découpage d'une forme en base(s) et flexion(s). Le suffixe de la base est substitué par un autre.

Par exemple, pour le mot *travaux*, l'analyseur cherche dans un premier temps la base *travaux* dans le dictionnaire, qu'il ne va évidemment pas trouver. Il ramène alors cette forme au cas régulier en substituant -ails à la flexion -aux (i.e. *travaux* en *travails*). Une régularisation de forme a été effectuée.

A cela, il associe la base *travail* au modèle de flexion adéquate et peut générer les informations suivantes, après découpage :

travail (nom) + s → masculin, pluriel

Pour l'analyse de *place*, l'analyseur ne trouvant pas de base *plac* après découpage en *plac* et -a, il ajoute un -e à cette dernière (1^{ère} régularisation de base). La base *place* n'étant toujours pas dans le dictionnaire, il substitue le *ce* en *ce* (2^{ème} régularisation de base) et obtient la base *place*. Les informations liées à cette base permettent de générer les informations suivantes :

place (radical du verbe placer) + a → 3^{ème} personne du singulier du passé-simple.

⁴ La catégorie F regroupe les noms et adjectifs, la catégorie V les verbes.

⁵ Comme le souligne l'équipe du CRISS (Lallich-Boidin et al., 1990), les exceptions nécessitent souvent des données de grande taille par rapport aux cas dits « généraux ». C'est pourquoi ces phénomènes sont transformés des les premiers traitements, afin d'éviter une surcharge de la taille des données de l'analyseur.

3.2.2 Les limites du système pour l'ALAO

Si nous tentons d'analyser des formes morphologiquement erronées avec le modèle tel quel, nous soulevons deux types de problèmes illustrés à travers les exemples suivants :

nationals → national + s → national (adj.) + flexion → *national*, masculin, pluriel, forme correcte de nombre

journeaux → régularisation : journeals → journeal + s → aucune analyse (la base *journeal* n'existe pas dans le dictionnaire)

Ces deux exemples montrent que l'analyseur du CRISS n'a pas été conçu pour analyser des formes erronées. Toutefois, le premier exemple montre que le découpage effectué est pertinent et facilement adaptable à notre problème. Le second exemple met en avant les cas où aucun découpage n'aboutit à une analyse. Nous avons donc modifié le modèle existant afin de pouvoir découper toutes les formes erronées et ainsi les analyser.

3.3 Le module d'analyse morphologique des réponses d'apprenants

Afin d'adapter le modèle du CRISS, il est important de savoir comment il se comporte face à des erreurs, et s'il est capable de les découper en base et flexions. Si ce découpage est possible, alors l'erreur peut être détectée et analysée. Notre préoccupation est donc de modifier le modèle au minimum afin de permettre ce découpage.

Dans un premier temps, nous avons expérimenté la généralisation à travers les données mêmes du modèle, afin de mettre en évidence tous les cas de généralisation possibles au sein du modèle et de mesurer ses potentialités. Les résultats montrent que la totalité des formes obtenues sont découposables.

Nous avons ensuite réalisé un test du système sur les erreurs du corpus FRIDA (57 pour les noms et adjectifs, 90 pour les verbes). Nous les avons tout d'abord classées selon qu'elles sont découposables par les données d'origine du modèle ou non. Ce classement a révélé un taux important pour les erreurs de généralisation et surgénéralisation, autant pour les verbes que pour les noms et adjectifs. Nous avons élargi les types d'erreurs à traiter grâce au corpus qui a mis en avant des cas de sous-généralisation où l'erreur est due à un oubli de régularisation (e.g. *nationals*).

Le principal défaut du modèle du CRISS repose sur le fait qu'il n'associe pas les régularisations avec les bases et flexions adéquates, ce qui entraîne une surgénération d'erreurs analysées comme forme correcte. Par exemple, la forme *carnavaux* sera analysée comme la forme régularisée au pluriel en *-aux* de la base *carnaval*.

Par conséquent, l'une des principales modifications de ce modèle va consister à intégrer les régularisations de forme et de base à l'intérieur même des modèles de flexions.

Ceci implique la modification des modèles existants, mais également la création de nouveaux modèles qui permettent d'intégrer chaque régularisation.

Afin de traiter les cas d'utilisation de flexion et de régularisations erronées⁶ (e.g. *journeaux*),

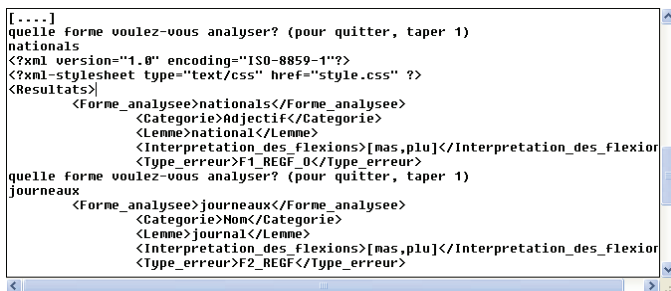
⁶ Nous entendons par *erronée* le fait que l'emploi de ce type de flexions et de régularisation fasse échouer l'analyse de ces fautes par l'analyseur non-modifié, car ni ces flexions, ni ces régularisations n'existent dans la langue française.

nous avons ajouté ces régularisations et flexions erronées au modèle. (e.g. la régularisation erronée *-eaux* en *-als* en plus de la régularisation existante *-aux* en *-als*).

Après la modification du modèle, nous obtenons 88 modèles de flexions, contre 61 à l'origine, et 83 règles de régularisations contre 63. Quant au dictionnaire, nous avons modifié de façon semi-automatique les 70 000 entrées afin d'associer les modèles de flexions à chaque base.

Nous trouvons judicieux, en plus des informations « classiques » générées par l'analyse morphologique, de créer une typologie des erreurs de morphologie flexionnelle, en nous appuyant sur le corpus FRIDA et sur le modèle (i.e. mauvaise manipulation des règles de régularisations). Cette typologie permet de proposer une première interprétation, éventuellement utilisable pour la future génération du feed-back. Par exemple, *nationals* est typé comme un oubli d'une régularisation de forme (i.e. *-aux* en *-als*) via le code F1_REGF_O généré lors de son analyse. Quant à *journeaux*, son analyse produit le code F2_REGF, qui correspond à une utilisation d'une régularisation de forme inexistante en français (i.e. *-eaux* en *-als*).

Le module a été réalisé en Prolog II+⁷, pour sa capacité à séparer données et algorithmes (grammaire déclarative) et pour son principe de *backtracking* (qui permet une analyse combinatoire et multiple). Voici la sortie proposée par notre analyseur pour les deux formes vues précédemment :



```
[....]
quelle forme voulez-vous analyser? (pour quitter, taper 1)
nationals
<?xml version="1.0" encoding="ISO-8859-1"?>
<?xml-stYLESHEET type="text/css" href="style.css" ?>
<Resultats>
  <Forme_analysee>nationals</Forme_analysee>
  <Categorie>Adjectif</Categorie>
  <Lemme>national</Lemme>
  <Interpretation_des_flexions>[mas,plu]</Interpretation_des_flexions>
  <Type_erreur>F1_REGF_O</Type_erreur>
quelle forme voulez-vous analyser? (pour quitter, taper 1)
journeaux
  <Forme_analysee>journeaux</Forme_analysee>
  <Categorie>Nom</Categorie>
  <Lemme>journal</Lemme>
  <Interpretation_des_flexions>[mas,plu]</Interpretation_des_flexions>
  <Type_erreur>F2_REGF</Type_erreur>
```

Figure 1 : Sorties de l'analyseur pour les formes *nationals* et *journeaux*.

Lors de l'analyse de *nationals*, l'algorithme découpe la forme en *national-* et *-s*. Il vérifie ensuite la présence de la base dans le dictionnaire. Grâce à cela, il récupère le modèle associé au lemme et compare les flexions et les régularisations effectuées lors du découpage par rapport aux flexions et régularisations autorisées (et obligatoires) du modèle. Il observe une incohérence sur une régularisation qui n'a pas été effectuée par l'apprenant pour former le masculin pluriel de *national*. Il génère un diagnostic en conséquence, puis tente un nouveau découpage (*nationa* + *ls*, etc.), sans succès.

Pour *journeaux*, aucun découpage ne permet d'extraire une base appartenant au dictionnaire. Il effectue donc une régularisation de forme (*-eaux* en *-als*), puis découpe la forme en *journal-* et *-s*. Les données associées au lemme ne correspondent pas aux données du

⁷ <http://www.prologia.fr/>

découpage, au niveau de la régularisation qui est en fait une régularisation erronée. Il détecte ainsi une erreur et génère la rétroaction, comme montré ci-dessus (figure 1).

4 Conclusion et perspectives

Nous avons développé un module permettant la détection et l'analyse d'erreurs morphologiques en situation hors-contexte. Il donne des résultats tout à fait prometteurs quant à l'analyse des erreurs issues du corpus FRIDA (toutes les erreurs sont correctement analysées). Il est évident qu'il est nécessaire de tester ce module sur un corpus plus important que ce dernier, afin de valider notre démarche, et de compléter notre modélisation linguistique des erreurs morphologiques existantes.

Il serait intéressant d'intégrer ce module dans un système existant d'ALAO, afin de définir sa plus-value et la robustesse qu'il peut apporter à celui-ci. La prochaine étape de ce travail va ainsi consister à implémenter cette analyse au sein de la plateforme MIRTO (Antoniadis et al., 2005a) qui à l'heure actuelle se fonde sur une analyse à 4 niveaux (Kraif, 2005). Cette dernière n'est pas capable de générer des rétroactions sur des erreurs morphologiques. En effet, son analyse considère *chevals* comme une erreur d'orthographe, en trouvant une ressemblance graphique entre *chevals* et *cheval*, et ne peut extraire aucune information expliquant l'erreur de l'apprenant.

Ce module constitue une première pierre dans la réalisation d'un dispositif complet capable de détecter et interpréter les réponses d'apprenants. Il convient à présent d'élargir le type des erreurs à analyser. C'est dans cette optique que s'inscrivent mes travaux de thèse. Une première étape consistera à définir les types d'activités qui seront susceptibles d'être évaluées par des outils issus du TAL. Puis, nous établirons un corpus de productions d'apprenants via les activités retenues. Ces données permettront ensuite d'établir une typologie attestée des erreurs rencontrées. A partir de ces recherches, la conception d'un système TAL d'évaluation des productions et de génération de rétroactions pourra alors être menée.

Références

ÅGREN M. (2005). La morphologie du nombre dans le système verbal en français L2 écrit- L'accord de la 3^{ème} personne du pluriel. Acquisition et production de la morphologie flexionnelle. *Actes du Festival de la morphologie*. Jonas Granfeldt et Suzanne Schlyter Eds, Lund (Suède).

ANTONIADIS G., ECHINARD S., KRAIF O., LEBARBÉ T., PONTON C. (2005a). Modélisation de l'intégration des ressources TAL pour l'apprentissage des langues : la plateforme MIRTO. *Revue ALSIC*, 8.

ANTONIADIS G., FAIRON C., GRANGER S., MEDORI J., ZAMPA V. (2006). Quelles machines pour enseigner la langue. *TALN 2006*, Leuven.

ANTONIADIS G., PONTON C., ECHINARD S. (2005b). Le TAL au service de l'évaluation automatique des fautes d'apprenants. Du vrai / faux à l'évaluation pédagogique. *Actes du colloque UNTELE*.

ASTOLFI J.P. (1997). *L'erreur, un outil pour enseigner*. Paris : Editions ESF.

- BERRENDONNER A. (1990). *Grammaire pour un analyseur. Aspects morphologiques*. France : Les Cahiers du CRISS.
- BOUILLON P., VANDOOVEREN F., DA SYLVA L., JACQMIN L., LEHMANN S., RUSSEL G., VIEGAS E. (1998). *Traitement automatique des langues naturelles*. Paris : Duculot.
- CORDIER-GAUTHIER C., DION C. (2003). Correction et révision de l'écrit en français langue seconde : médiation humaine, médiation informatique. *Revue ALSIC*, 24,29-43.
- FAYOL M. (2001). Compte-rendu de la conférence donnée par M. Fayol à l'IUFM de Poitou-Charentes, site des Deux-Sèvres à Niort, dans le cadre des Conférence de L'Ais : *Apprendre à utiliser l'orthographe*.
- FUCHS C., DANLOS L., LACHERET-DUJOUR A., LUZATTI D., VICTORRI B. (1993). *Linguistique et Traitement Automatique des Langues*. France : Hachette.
- GRANGER S., VANDEVENTER A., HAMEL M.J. (2001). *Analyse de corpus d'apprenants pour l'ELAO basé sur le TAL*. Paris : Hermès.
- KRAIF O. (2005). Evaluation automatique de productions lexicales : une analyse à 4 niveaux. *Actes du colloque UNTELE*.
- LALLICH-BOIDIN G., HENNERON G., PALERMATI R. (1990). *Analyse du français. Achèvement et implantation de l'analyseur morpho-syntaxique*. France : Les Cahiers du CRISS (Centre de Recherche en Informatique appliquée au Sciences Sociales.
- LANCIEN T. (1997). *Le Multimédia (pp. 90-97)*. Clé International.
- L'HAIRE S., VANDEVENTER A. (2003). Diagnostic d'erreurs dans le projet FreeText. *Revue ALSIC*, vol. 6, n°2, 21-37.
- NIELSEN J. (1993). *Usability engyneering*. New York: Academic Press.
- RÉZEAU J. (2004). *Médiatisation et médiation pédagogique dans un environnement multimédia. Le cas de l'apprentissage de l'anglais en Histoire de l'Art*. Thèse de doctorat de l'université Bordeaux 2 (pp. 356-367).
- SILBERZTEIN M. (1993). *Dictionnaires électroniques et analyse automatique de textes : le système INTEX*. Paris : Masson.
- WYATT D.H. (1988). *Applying pedagogical principles to CALL courseware development*, in *Modem Media in Foreign Language Education : Theory and implementation*. Illinois : National Textbook.