

D-STAG : un formalisme pour le discours basé sur les TAG synchrones

Laurence DANLOS

LATTICE – Université Paris 7

Institut Universitaire de France

Laurence.Danlos@linguist.jussieu.fr

Résumé. Nous proposons D-STAG, un formalisme pour le discours qui utilise les TAG synchrones. Les analyses sémantiques produites par D-STAG sont des structures de discours hiérarchiques annotées de relations de discours coordonnantes ou subordonnantes. Elles sont compatibles avec les structures de discours produites tant en RST qu'en SDRT. Les relations de discours coordonnantes et subordonnantes sont modélisées respectivement par les opérations de substitution et d'adjonction introduites en TAG.

Abstract. We propose D-STAG, a framework which uses Synchronous TAG for discourse. D-STAG semantic analyses are hierarchical discourse structures richly annotated with coordinating and subordinating discourse relations. They are compatible both with RST and SDRT discourse structures. Coordinating and subordinating relations are respectively modeled with the TAG substitution and adjunction operations.

Mots-clés : discours, grammaires d'arbres adjoints (synchrones), interface syntaxe/sémantique.

Keywords: discourse, (synchronous) tree adjoining grammars, syntax/semantic interface.

1 Introduction

RST - Rhetorical Structure Theory (Mann & Thompson, 1988; Taboada & Mann, 2006) - et SDRT - Segmented Discourse Representation Theory (Asher, 1993; Asher & Lascarides, 2003) - sont deux théories pour le discours qui reposent sur la notion de *relation de discours*. Ces théories partagent l'idée que certaines parties d'un discours, appelées *Satellites*, jouent un rôle « subordonné » (« moins important ») que d'autres parties, appelées *Nucleus*. Cette asymétrie est comparable à la distinction faite au niveau syntaxique entre les arguments (*nuclei*) et les adjoints (*satellites*) d'une phrase. Elle amène à poser l'existence de deux types de relations de discours : une relation *coordonnante* (*multi-nucléaire*) relie deux *Nuclei*, tandis qu'une relation *subordonnante* (*nucleus-satellite*) relie un *Nucleus* et un *Satellite*. Elle permet la construction de structures de discours hiérarchiques annotées de relations coordonnantes ou subordonnantes.

Nous proposons ici un nouveau formalisme pour le discours, D-STAG (Discourse Synchronous TAG), qui utilise aussi les relations de discours coordonnantes et subordonnantes et qui repose

sur STAG - Synchronous TAG (Shieber, 1994; Shieber & Schabes, 1990). STAG a été utilisé avec succès dans une grammaire anglaise qui permet d'engendrer simultanément les analyses syntaxique et sémantique d'une phrase (Nesson & Shieber, 2006). Dans le prolongement de cette idée, une grammaire D-STAG pour le français ou l'anglais permet d'engendrer simultanément les analyses syntaxique et sémantique d'un discours français ou anglais donné en entrée. Les analyses sémantiques des discours sont des structures hiérarchiques annotées par des relations coordonnantes ou subordonnantes. Elles peuvent être converties de façon déterministe en structures RST ou SDRT. Par conséquent, D-STAG peut bénéficier des résultats apportés par ces théories du discours, par exemple, D-STAG peut bénéficier de la *Contrainte de la Frontière Droite* (Section 2.2), qui simplifie grandement le calcul des structures de discours.

En D-STAG, les relations de discours coordonnantes et subordonnantes sont modélisées respectivement par les opérations de substitution et d'adjonction introduites en TAG- Tree Adjoining Grammar (Joshi, 1985). En TAG, les arbres initiaux introduisent les dépendances prédicat-arguments par substitution, tandis que les arbres auxiliaires introduisent la récursivité et permettent la modification d'arbres élémentaires grâce à l'opération d'adjonction. D-STAG suit ces principes de base de TAG ; plus précisément, les relations coordonnantes ancrent des arbres initiaux qui introduisent leurs arguments (deux Nuclei) par substitution, tandis que les relations subordonnantes ancrent des arbres auxiliaires : le Satellite d'une relation subordonnante modifie son Nucleus par l'adjonction d'un arbre auxiliaire ancré par la relation subordonnante.

Une grammaire D-STAG est une extension naturelle d'une grammaire STAG réalisant une interface syntaxe/sémantique pour les phrases. Dans cette perspective, le même analyseur peut être utilisé tant pour les phrases que pour les discours, et les formes logiques des discours peuvent être calculées de façon déterministe à partir des analyses sémantiques calculées en D-STAG en employant les formes logiques des phrases (qui sont calculées de façon déterministe à partir de leurs analyses sémantiques produites par la grammaire STAG).

D-STAG ressemble à D-LTAG - Discourse Lexicalized TAG dans la version présentée dans (Forbes-Riley *et al.*, 2006) - dans la mesure où les deux formalismes étendent une interface syntaxe/sémantique phrastique au niveau du discours. Cependant, il existe une différence cruciale : D-LTAG n'utilise pas les relations de discours et ignore la distinction entre relations coordonnantes et subordonnantes. Par conséquent, D-LTAG n'a rien de commun avec RST ou SDRT.

Cet article est organisé de la façon suivante : la Section 2 introduit brièvement RST et SDRT, la Section 3 STAG. La Section 4 expose les principes de D-STAG. La Section 5 compare D-LTAG et D-STAG. Le même exemple de référence est utilisé dans toutes les sections, à savoir (1) qui est de la forme P_1 *parce que* P_2 . *Ensuite*, P_3 ., dans lequel *parce que* exprime la relation subordonnante Explication et *ensuite* la relation coordonnante Narration.

(1) Jean est allé au super-marché parce que son frigo était vide. Ensuite, il est allé au cinéma.

2 Brève introduction à RST et SDRT

RST et SDRT reposent sur la notion de relation de discours et emploient *grosso modo* le même ensemble de relations de discours¹. Des débats ont lieu sur la distinction Nucleus/Satellite de

¹Il arrive qu'une relation de discours donnée soit nommée de deux façons différentes. Par exemple, Séquence en RST est appelée Narration en SDRT.

RST (Stede, 2007) et sur la distinction coordonnante/subordonnante de SDRT (Asher & Vieu, 2005). Cependant, on suppose ici que le statut d’une relation de discours (coordonnante versus subordonnante) est clair et identique en RST et SDRT². RST et SDRT proposent des structures de discours graphiquement différentes, comme montré dans les deux sections suivantes.

2.1 Structures de discours en RST

RST est une théorie qui a été conçue il y a une vingtaine d’années et qui a été beaucoup employée. De ce fait, il existe différentes interprétations de RST (Taboada & Mann, 2006). Dans cet article, nous ne parlerons que de l’interprétation de Marcu, qui a eu un fort impact en analyse de discours (Marcu, 2000) et annotation de discours (Carlson *et al.*, 2003).

Pour un discours donné, RST calcule une structure d’arbre qui connecte récursivement les unités minimales (les clauses) et les segments de texte plus larges ainsi construits ; une relation de discours ne peut relier que des segments de texte adjacents. L’arbre RST pour (1), dans la représentation graphique de Marcu (2000), est donné dans la Figure 1(a). Le symbole C_i représente la phrase P_i , son analyse syntaxique ou son analyse sémantique (selon l’application dans laquelle RST est employée). Les étiquettes N et S sur les arcs abrègent respectivement Nucleus et Satellite.

Marcu (2000) a proposé un principe, appelé « Principe de Nucléarité » (ou « Principe compositionnel ») qui s’énonce comme suit : quand une relation de discours relie deux segments de discours, alors elle relie aussi les Nuclei de ces deux segments. Le Principe de Nucléarité donne l’interprétation en termes de prédicats et arguments à un arbre RST. Par exemple, il indique que C_1 est l’argument gauche de Narration dans l’arbre pour (1) donné dans la Figure 1(a).




FIG. 1 – Arbre RST (a) et graphe SDRT (b) pour le discours (1)

2.2 Structures de discours en SDRT

À l’origine, SDRT a été conçue comme une extension de la DRT - Discourse Representation Theory (Kamp & Reyle, 1993) - pour rendre compte des propriétés spécifiques du discours. Toutefois, cette théorie s’est inspirée de RST, par exemple, la distinction coordonnante/subordonnante faite en SDRT est inspirée de la distinction multi-nucléaire/nucleus-satellite faite en RST.

Les structures de discours en SDRT sont représentées comme des graphes dirigés conçus avec les principes suivants. Pour un discours composé de deux phrases (clauses) liées par une relation

²Ceci est le cas la plupart du temps, excepté pour Résultat qui est subordonnante en RST et coordonnante en SDRT, bien que (Asher & Vieu, 2005) postulent que Résultat est coordonnante ‘par défaut’.

de discours R , les nœuds du graphe sont les étiquettes π_1 et π_2 des DRS donnant les formes logiques des phrases. Ils sont liés par une *flèche* qui est étiquetée par la relation R . La flèche est horizontale si R est coordonnante, verticale si R est subordonnante (Asher & Vieu, 2005). Si l'on prend en compte la distinction Nucleus/Satellite, ceci signifie qu'une flèche horizontale relie deux Nuclei, tandis qu'une flèche verticale descend d'un Nucleus vers un Satellite. En plus des nœuds représentant les phrases (notés π_i et appelés « nœuds de phrase »), les graphes SDRT peuvent comporter des « nœuds de portée » (notés π' , $\pi >>$, ...). Un nœud de portée est lié par des *lignes* à des nœuds de phrase. Pour (1), le graphe SDRT est donné dans la Figure 1(b).

Lors de la procédure de construction des structures de discours, SDRT fait appel à la notion de *frontière droite*, proposée à l'origine par (Polanyi, 1988). Informellement, dans le graphe SDRT pour un discours comportant n phrases (clauses), la frontière droite contient le nœud π_n représentant la dernière phrase et les autres nœuds de phrase situés sur la frontière droite du graphe³. A titre d'illustration, la frontière droite dans le graphe de la Figure 1(b) contient seulement le nœud π_3 . Lors de la construction dynamique d'un graphe SDRT, les nœuds de la frontière droite sont les seuls nœuds qui permettent d'accrocher une information nouvelle ; ceci est connu sous le nom de « Contrainte de la Frontière Droite »⁴. Cette contrainte simplifie grandement la construction des structures de discours, et par là-même le calcul des formes logiques des discours, qui sont obtenues de façon déterministe à partir des structures de discours.

3 Introduction aux TAG synchrones

Les parties entre guillemets de cette section sont traduites de (Nesson & Shieber, 2006). Les opérations de substitution et adjonction introduites en TAG pour la syntaxe sont rappelées dans le Figure 2.




FIG. 2 – Exemples des opérations de substitution (a) et d'adjonction (b) en TAG

« Les TAG synchrones (STAG) prolongent les TAG en considérant les structures élémentaires comme des paires d'arbres TAG avec des liens entre certains nœuds de ces arbres. Une STAG est un ensemble de triplets $\langle t_L, t_R, \sim \rangle$ où t_L et t_R sont des arbres élémentaires TAG et \sim est une relation de liage entre certains nœuds de t_L et certains nœuds de t_R (Shieber, 1994; Shieber & Schabes, 1990). La dérivation se déroule comme en TAG excepté que toutes les opérations doivent être appariées. En d'autres mots, un arbre ne peut être substitué ou adjoint à un nœud que si l'arbre apparié est simultanément substitué ou adjoint au nœud lié. Nous notons les liens en utilisant des indices dans des cercles (e.g. ①) qui viennent décorer les nœuds liés. »

³En fait, la frontière droite contient aussi les « nœuds topiques » situés sur la frontière droite du graphe. La notion de nœud topique est importante en SDRT, mais elle est laissée de côté dans cet article.

⁴Cette contrainte dit aussi que l'antécédent d'une expression anaphorique doit être sur la frontière droite, mais les expressions anaphoriques ne sont pas discutées ici.

STAG a été utilisé avec succès dans une interface syntaxe/sémantique pour l’anglais qui peut traiter de phrases complexes soulevant des problèmes délicats de portée (Nesson & Shieber, 2006). Cette interface est illustrée dans la Figure 3 pour l’analyse de la phrase (très simple) *John apparently likes Mary*.




FIG. 3 – Fragment d’une interface syntaxe/sémantique pour l’anglais (a), les paires d’arbres dérivés (b) et l’arbre de dérivation (c) pour la phrase *John apparently likes Mary*. (Figure reproduite à partir de (Nesson et Shieber, 2006))

Dans l’arbre de dérivation, « les opérations de substitution sont notées avec une ligne continue, celles d’adjonction avec une ligne en pointillés. Il faut noter que chaque lien de l’arbre de dérivation spécifie un numéro de liage dans la paire d’arbres élémentaires. Ces liens donnent l’adresse des opérations dans l’arbre syntaxique et dans l’arbre sémantique. Ces opérations doivent opérer à des nœuds liés dans la paire d’arbres élémentaires concernée. »

Les arbres dérivés sémantiques permettent de calculer de façon déterministe les formes logiques des phrases, par exemple la forme *apparently(likes(john, mary))* à partir de l’arbre dérivé sémantique de la phrase *John apparently likes Mary*.

4 Présentation de D-STAG

D-STAG utilise STAG pour le discours, une grammaire D-STAG étant une extension naturelle d’une grammaire STAG réalisant une interface syntaxe/sémantique au niveau phrastique. Une paire d’arbres élémentaires en D-STAG consiste en un arbre élémentaire ancré par un connecteur de discours et comportant **deux** nœuds non terminaux⁵ apparié avec un arbre élémentaire ancré par la relation de discours exprimée par le connecteur et comportant **deux** nœuds non terminaux. Pour une relation de discours coordonnante, l’arbre élémentaire est un arbre initial comportant deux nœuds à substitution correspondant aux deux Nuclei. Pour une relation subordonnante *R*, il existe deux arbres élémentaires associés aux positions du Satellite vis-à-vis du Nucleus ; la notation *R_r* (resp. *R_l*) signifie que le Satellite apparaît à la droite (resp. gauche) du Nucleus.

⁵L’arbre D-STAG d’un connecteur n’est pas forcément similaire à son arbre syntaxique. De ce fait, un analyseur D-STAG doit inclure un module d’extraction d’arbres et un module de correspondance entre arbres syntaxiques et arbres discursifs, comme c’est le cas dans l’analyseur pour D-LTAG décrit dans (Webber, 2004).

Ces arbres élémentaires sont des arbres auxiliaires dont le nœud pied correspond au Nucleus et qui comportent un nœud à substitution correspondant au Satellite.

La Figure 4 contient quatre paires d'arbres : la première, nommée α ensuite-Narration⁶ apparie l'arbre initial pour *ensuite* avec l'arbre initial pour Narration exprimée par *ensuite*. Les deux suivantes, nommées β parce-que-Explication_R et β parce-que-Explication_L, appartiennent les arbres auxiliaires pour *parce que* avec ceux pour la relation subordonnante Explication exprimée par *parce que*⁷. La dernière paire d'arbres, nommée α P-to-D, est spéciale : elle est conçue pour immerger dans une grammaire D-STAG les analyses syntaxique et sémantique d'une phrase engendrées par une grammaire STAG. Expliquons les symboles non terminaux figurant dans ces paires d'arbres. Les symboles DC et DR sont respectivement utilisés pour les connecteurs de discours (« discourse connectives ») et les relations de discours (« discourse relations ») ; les nœuds étiquetés DC ou DR sont liés par l'indice ③ dont l'emploi sera illustré pour le discours (2) ci-dessous. Les symboles DU et AO sont respectivement utilisés pour les unités de discours (« discourse units ») et les objets abstraits (« abstract objects », (Asher, 1993)). Une unité de discours peut être simple ou complexe. Une unité de discours simple est l'analyse syntaxique d'une phrase « simple » (i.e. une phrase ne comportant pas de connecteur de discours), soit un arbre de racine *P* qui est introduit au niveau discursif par α P-to-D. Une unité de discours complexe est récursivement l'analyse syntaxique d'une phrase complexe (comportant un ou plusieurs connecteurs) ou d'un texte de plusieurs phrases. Parallèlement, les objets abstraits simples ou complexes sont des analyses sémantiques ; un objet abstrait simple est un arbre de racine *t* qui est introduit au niveau discursif par α P-to-D. Signalons que l'étiquetage par N (Nucleus) ou S (Satellite) des arcs pointant sur les nœuds AO dans les arbres élémentaires ancrés par une relation de discours est une information qui est juste destinée à la conversion d'une analyse sémantique de D-STAG en un arbre RST (voir Figure 6(a) ci-dessous).




FIG. 4 – Fragment d'une grammaire D-STAG pour le français

Montrons maintenant comment les paires d'arbres de la Figure 4 sont utilisées pour analyser le discours (1). La Figure 5 contient les paires d'arbres dérivés (a)-(b) pour (1), et l'arbre de

⁶Une paire d'arbres élémentaires en D-STAG est nommée avec les conventions suivantes : le préfixe α ou β indique si les arbres appariés sont initiaux (α) ou auxiliaires (β) ; le nom concatène les ancres des arbres élémentaires, i.e. un connecteur de discours et une relation de discours.

⁷Dans les phrases de forme P_1 parce que P_2 , ou *Parce que* P_1 , P_2 ., les nœuds pied proviennent structurellement des phrases principales, les nœuds à substitution des phrases subordonnées. Néanmoins, dans les phrases de forme P_1 Conj P_2 parce que S_3 ., dans lesquelles *Conj* désigne une autre conjonction de subordination, le nœud pied de *parce que* n'est pas structurellement défini : il provient de P_1 , de P_2 ou de P_1 Conj P_2 (Danlos, 2004).

dérivation (c). En supposant que les analyses syntaxique et sémantique d'une phrase simple sont engendrées simultanément par une grammaire STAG, le symbole T_i représente l'analyse syntaxique de la phrase P_i (un arbre de racine P), F_i son analyse sémantique (un arbre de racine t), τ_i son arbre de dérivation. Nous emploierons les termes suivants : dans la Figure 5, (a) est l'*analyse syntaxique discursive* de (1), (b) son *analyse sémantique discursive*, (c) son *analyse sémantique compositionnelle*.




FIG. 5 – Paire d'arbres dérivés (a)-(b) et arbre de dérivation (c) calculés en D-STAG pour (1)

Nous allons maintenant montrer comment les analyses de D-STAG se convertissent en structures de discours RST ou SDRT. Les analyses sémantiques discursives de D-STAG sont convertibles de façon déterministe en arbres RST, par exemple l'analyse (b) de (1) est convertible en l'arbre RST pour (1) - Figure 1(a) - en appliquant récursivement le patron donné dans la Figure 6(a). Les symboles l_1 ou l_2 sur les arcs ont pour valeur N (Nucleus) ou S (Satellite)⁸. La conversion d'analyses sémantiques de D-STAG en arbres RST s'explique en reconsidérant le Principe de Nucléarité (Section 2.1) à la lumière de l'opération d'adjonction. Par exemple, dire que C_1 est l'argument gauche de Narration dans l'arbre RST de la Figure 1(a) (grâce au Principe de Nucléarité) revient à dire que le sous-arbre dont la racine est la relation subordonnante Explication est introduit par **adjonction**. C'est la raison pour laquelle nous avons postulé que les relations de discours subordonnantes ancrent des arbres **auxiliaires** en D-STAG. Comme la distinction Nucleus/Satellite faite en RST est similaire à la distinction argument/adjoint faite en syntaxe, les relations subordonnantes sont modélisées par l'opération d'adjonction, tandis que les relation coordonnantes sont modélisées par l'opération de substitution (Section 1).




FIG. 6 – Patrons de conversion d'une analyse sémantique de D-STAG vers un arbre RST (a) et d'une analyse compositionnelle de D-STAG vers un graphe SDRT (b)

Passons aux structures de discours SDRT. Les analyses sémantiques compositionnelles de D-STAG sont convertibles de façon déterministe en graphes SDRT, par exemple l'analyse (c) de (1) est convertible selon le graphe SDRT pour (1) - Figure 1(b) - en appliquant récursivement les patrons donnés dans la Figure 6(b). Pour simplifier la lecture de ces patrons, nous avons utilisé les symboles τ'_i qui représentent α P-to-D dans lequel τ_i est substitué au lien ①.

⁸Un constituant C_i est soit une phrase, soit son analyse syntaxique, soit son analyse sémantique (alors $C_i = F_i$), selon l'interprétation et l'utilisation de RST (Section 2.1). Dans tous les cas, C_i peut être obtenu à partir de F_i .

Les analyses sémantiques compositionnelles de D-STAG conduisent de façon déterministe aux formes logiques. Par exemple, l'arbre de dérivation (c) pour (1) conduit à la forme logique (simplifiée) suivante : $F_1 \wedge F_2 \wedge F_3 \wedge precede(F_1, F_3) \wedge cause(F_2, F_1)$. En suivant SDRT, ce calcul demande simplement d'interpréter $Narration(\pi_1, \pi_3)$ en $F_1 \wedge F_3 \wedge precede(F_1, F_3)$ et $Explication(\pi_1, \pi_2)$ en $F_1 \wedge F_2 \wedge cause(F_2, F_1)$.

En conclusion, les analyses sémantiques discursives et compositionnelles de D-STAG sont respectivement convertibles en structures de discours RST et SDRT. Par conséquent, D-STAG peut bénéficier des résultats apportés par ces théories du discours. Par exemple, D-STAG peut profiter de la Contraint de la Frontière Droite (Section 2.2) pour simplifier grandement la construction des structures de discours et par là-même le calcul des formes logiques de discours.

De plus, D-STAG peut profiter de l'opération d'adjonction pour la *modification* des relations de discours, un phénomène qui n'est pas traité en RST ou SDRT. Ce phénomène est illustré par le discours (2).

- (2) Tu ne dois pas faire confiance à Jean parce que, par exemple, il ne rend jamais ce qu'il a emprunté.
(Exemple traduit de (Webber *et al.*, 2003))

Comme expliqué dans (Webber *et al.*, 2003), l'interprétation de (2) est que le non retour par Jean des objets empruntés est un exemple des raisons pour ne pas lui faire confiance. Guidée par cette interprétation, nous postulons que *par exemple* dans ce discours est un modifieur de *parce que*. De ce fait, nous postulons qu'en D-STAG cet adverbial ancre un arbre auxiliaire syntaxique dont la racine est un nœud étiqueté DC et qui est apparié avec un arbre auxiliaire sémantique dont la racine est étiquetée DR et dont l'ancre est simplement *par-ex*⁹. La paire d'arbres ainsi formée, appelée $\beta\text{par-ex}$, est montrée dans la Figure 7(a). Lors de l'analyse de (2), $\beta\text{par-ex}$ s'adjoint au lien ③ dans $\beta\text{parce_que-Explication}_R$ donné dans la Figure 4. L'analyse compositionnelle de (2) est présentée dans la Figure 7(b).




FIG. 7 – Paire $\beta\text{par-ex}$ (a) et analyse compositionnelle de (2) (b)

La forme logique de (2), e.g. $Exemplify(F_2, \lambda F.cause(F, F_1))$ donnée dans (Forbes-Riley *et al.*, 2006), est calculée simplement à partir de l'arbre de dérivation de (2) en interprétant $\beta\text{par-ex}$ selon la forme abstraite $Exemplify(?X_2, \lambda F.?R(F, ?X_1))$ dans laquelle les variables $?R$, $?X_1$ et $?X_2$ prennent leur valeur dans l'arbre de dérivation où $\beta\text{par-ex}$ est adjoint.

Nous concluons cette présentation de D-STAG par une remarque sur l'ambiguïté au niveau discursif. Il arrive souvent qu'un connecteur de discours soit sémantiquement ambigu, i.e. exprime

⁹Par contre, en D-LTAG, *for example* (*par exemple*) est considéré comme un connecteur de discours en (2). En D-STAG, cet adverbial n'est un connecteur de discours (exprimant la relation de discours Exemplification) que dans un discours comme *Jean adore le fromage. Par exemple, il adore le brie.*

plusieurs relations de discours. C'est le cas entre autres pour le connecteur vide ϵ ¹⁰ qui exprime les relations Explication_r, Elaboration_r et Narration, entre autres. En D-STAG, un connecteur ambigu ancre autant d'arbres élémentaires syntaxiques qu'il a d'interprétations, ce qui conduit à une paire d'arbres pour chaque interprétation. Le choix de la bonne interprétation pour un connecteur ambigu dépend de considérations (extra)-linguistiques. Par exemple, le discours (3) doit recevoir les analyses présentées dans la Figure 8.

(3) Jean est allé au super-marché parce que son frigo était vide. Il a acheté un rôti et du brie.




FIG. 8 – Paire d'arbres dérivés (a)-(b) et arbre de dérivation (c) calculés en D-STAG pour (3)

Le fait que le connecteur vide ϵ introduisant P_3 dans (3) exprime la relation Elaboration_r vient de la connaissance qu'on va au super-marché pour faire des achats. La prise en compte de considérations (extra)-linguistiques demande des techniques comme celles mises en œuvre en SDRT, qui reposent sur une procédure incrémentale basée sur la « glue logique » (Asher & Lascarides, 2003). Une autre solution consiste à faire appel à des méthodes probabilistes, comme cela est proposé en D-LTAG en s'appuyant sur le *Penn Discourse TreeBank* (Webber, 2004). Ces deux solutions sont complémentaires.

5 Comparaison entre D-STAG et D-LTAG

D-STAG ressemble à D-LTAG - dans la version présentée dans (Forbes-Riley *et al.*, 2006) - dans la mesure où ces deux formalismes étendent une interface syntaxe/sémantique basée sur TAG au discours. Cependant, il existe une différence cruciale : D-LTAG n'utilise pas les relations de discours et ignore la distinction entre relations coordonnantes et subordonnantes. Les formes logiques des discours sont calculées par le même procédé que celui utilisé pour calculer les formes logiques des phrases. Ceci donne à D-LTAG une homogénéité certaine mais l'empêche de bénéficier des résultats apportés par les théories sur le discours.

Il existe une autre différence entre D-STAG et D-LTAG : les analyses syntaxiques des discours sont différentes car en D-STAG les connecteurs de discours ancrent des arbres élémentaires avec deux arguments, tandis qu'en D-LTAG ils peuvent ancrer des arbres avec un seul argument (qui est fourni *structurellement*, l'autre étant fourni *anaphoriquement* (Webber *et al.*, 2003; Webber, 2004)), e.g. l'arbre pour *ensuite* n'a qu'un seul argument¹¹.

¹⁰Dans un discours de la forme $P_1 . P_2$, dans lequel les phrases P_1 et P_2 ne sont pas liées par un item lexical (un connecteur de discours), on suppose que P_2 comporte le connecteur vide ϵ , ce qui s'écrit $P_1 . \epsilon P_2$. Une façon différente mais équivalente de voir les choses consiste à considérer le point séparant P_1 et P_2 comme un connecteur de discours (Danlos, 1998).

¹¹A titre d'illustration, l'analyse syntaxique de (1) fournie par D-LTAG est donnée ci-contre ;

6 Conclusion

D-STAG est un formalisme qui étend une interface syntaxe/sémantique développée en STAG au niveau du discours et qui prend en compte la pragmatique du discours. Une grammaire D-STAG génère des analyses qui peuvent être interprétées comme des structures RST ou SDRT. Les formes logiques pour les discours sont calculées de façon déterministe à partir des analyses compositionnelles (arbres de dérivation). Dans (Danlos, 2007), nous montrons comment traiter en D-STAG des phénomènes complexes de portée.

La recherche future concernera les discours dans lesquels un argument d'une relation de discours provient d'un segment de texte discontinu, ce qui arrive avec la relation Attribution quand un de ses arguments est enchâssé dans l'autre (qui est de ce fait discontinu). Nous pensons que la relation d'adjonction sera d'un grand secours pour ces cas. Ceux-ci demanderont d'entremêler les grammaires STAG phrastique et discursive, alors qu'elles ont été considérées comme fonctionnant séquentiellement (*en pipe-line*) dans cet article.

Références

- ASHER N. (1993). *Reference to Abstract Objects in Discourse*. Dordrecht : Kluwer.
- ASHER N. & LASCARIDES A. (2003). *Logics of Conversation*. Cambridge : Cambridge University Press.
- ASHER N. & VIEU L. (2005). Subordinating and coordinating discourse relations. *Lingua*, **115**(4), 591–610.
- CARLSON L., MARCU D. & OKUROWSKI M. E. (2003). Building a discourse-tagged corpus in the framework of rhetorical structure theory. In J. VAN KUPPEVELT & R. SMITH, Eds., *Current Directions in Discourse and Dialogue*, p. 85–112. Kluwer Academic Publishers.
- DANLOS L. (1998). G-TAG : un formalisme lexicalisé pour la génération de textes inspiré de TAG. *Revue TAL*, **39**(2).
- DANLOS L. (2004). Sentences with two subordinate clauses : syntactic and semantic analyses, underspecified semantic representation. In *Proceedings of TAG+7*, p. 140–147, Vancouver.
- DANLOS L. (2007). Flexible composition in D-STAG. In *Proceedings of MTT'07*, Klagenfurt, Austria.
- FORBES-RILEY K., WEBBER B. & JOSHI A. (2006). Computing discourse semantics : The predicate-argument semantics of discourse connectives in D-LTAG. *Journal of Semantics*, **23**(1).
- JOSHI A. (1985). Tree-adjointing grammars. In D. DOWTY, L. KARTTUNEN & A. ZWICKY, Eds., *Natural language parsing*, p. 206–250. Cambridge University Press.
- KAMP H. & REYLE U. (1993). *From Discourse to Logic*. Dordrecht : Kluwer Academic Publishers.
- MANN W. C. & THOMPSON S. A. (1988). Rhetorical structure theory : Toward a functional theory of text organization. *Text*, **8**(3), 243–281.
- MARCU D. (2000). *The Theory and Practice of Discourse Parsing and Summarization*. The MIT Press.
- NESSON R. & SHIEBER S. (2006). Simpler TAG semantics through synchronization. In *Formal Grammars*, Malaga.
- POLANYI L. (1988). A formal model of the structure of discourse. *Journal of Pragmatics*, **12**, 601–638.
- SHIEBER S. (1994). Restricting the weak-generative capacity of synchronous tree-adjointing grammars. *Computational Intelligence*, **10**(4), 371–385.
- SHIEBER S. & SCHABES Y. (1990). Synchronous tree-adjointing grammars. In *Proceedings of the 13th International Conference on Computational Linguistics*, volume 3, p. 253–258, Helsinki.
- STEDE M. (2007). RST revisited : Disentangling nuclearity.
- TABOADA M. & MANN W. (2006). Rhetorical structure theory : Looking back and moving ahead. *Discourse Studies*, **8**(3), 423–459.
- WEBBER B. (2004). DTAG : extending lexicalized TAG to discourse. *Cognitive Science*, **28**(5), 751–779.
- WEBBER B. L., JOSHI A., STONE M. & KNOTT A. (2003). Anaphora and discourse structure. *Computational Linguistics*, **29**(4), 545–587.

elle comporte trois nœuds étiquetés DC, un pour *parce que*, un pour ϵ , et un pour *ensuite*. Elle est différente de l'analyse syntaxique de (1) fournie par D-STAG - Figure 5(a) - qui ne comporte que deux nœuds étiquetés DC.

